

**Proyecto Final — Análisis Comparativo de Arquitecturas de
Aprendizaje Automático para el Monitoreo Superficial
Basado en Satélite**

Fase 1: Definición del Problema

Zona de estudio: Mar de Aral (Kazajistán / Uzbekistán)

Período: Junio – Septiembre de 2025

Equipo: *sigmasboys*

Juan Diego Muñoz Angulo

Joan Orduz Chia

Joshua Prieto Zambrano

David Roa Neisa

Repositorio: https://github.com/JoshuaPZz/Emergentes_Proyecto

Bogotá D.C., Colombia

Mayo de 2026

Índice

1. Definición del Evento y Justificación	3
1.1. Contexto general	3
1.2. Evento específico de análisis	3
1.3. Justificación de la selección	4
2. Área de Estudio y Límites Espaciales	4
2.1. Descripción geográfica	4
2.2. Extensión y bounding box	5
2.3. Sistema de referencia de coordenadas	5
3. Metadatos de Imágenes de Satélite	6
3.1. Plataforma y sensor	6
3.2. Bandas espectrales y resolución espacial	7
3.3. Índices espectrales derivados	8
4. Creación del Dataset de Entrenamiento	9
4.1. Clases de cobertura del suelo	9
4.2. Proceso de digitalización de polígonos	9
4.3. Estructura del archivo TSV	10
4.4. Flujo de trabajo y herramientas	10
5. Cronograma de Actividades — Fase 1	11
6. Correcciones y Ajustes Realizados	11
6.1. Ajustes en la Construcción del Dataset	12
6.2. Corrección de Atributos de Clasificación	12
6.3. Selección Temporal de Imágenes	12
6.4. Eliminación de Índices Espectrales	12
6.5. Organización y Repositorio	13
7. Fase 2 - Construcción del Dataset y Extracción de la Zona de Estudio	13
7.1. Selección de la Imagen Satelital	13
7.2. Definición de la Zona de Estudio	13
7.3. Bandas Espectrales Utilizadas	14
7.4. Construcción del Stack Multibanda	15
7.5. Generación de Muestras de Entrenamiento	15
7.6. Selección y Preparación de Bandas Espectrales	16
7.7. Construcción del Raster Multibanda	17

7.8. Preparación de Polígonos de Entrenamiento	18
8. Entrenamiento y Evaluación de Modelos de Machine Learning	19
8.1. Construcción del Dataset Supervisado	19
8.2. División de Datos Train/Test	20
8.3. Modelos de Machine Learning Utilizados	20
8.4. Métricas de Evaluación	21
8.5. Resultados Experimentales	22
8.6. Resumen del Dataset Utilizado	22
8.7. Métricas Comparativas de los Modelos	22
8.8. Selección del Mejor Modelo	23
8.9. Matrices de Confusión	23
8.9.1. Matriz de Confusión - Decision Tree	24
8.9.2. Matriz de Confusión - SVM	25
8.9.3. Matriz de Confusión - KNN	26
8.9.4. Matriz de Confusión - GaussianNB	27
8.9.5. Matriz de Confusión - MLPClassifier	28
8.9.6. Matriz de Confusión - Random Forest	29
8.10. Archivos y Resultados Generados	29
9. Conclusiones de la Fase de Entrenamiento y Clasificación Supervisada	30
10. Conclusión	31
Referencias	32

1. Definición del Evento y Justificación

1.1. Contexto general

El Mar de Aral fue durante el siglo XX el cuarto lago más grande del mundo, con una superficie aproximada de 68.000 km² y una profundidad media de unos 16 metros. Se ubica en Asia Central, en la frontera entre Kazajistán al norte y Uzbekistán al sur, y era alimentado principalmente por los ríos Amu Daria y Sir Daria. A partir de los años sesenta, el gobierno soviético desvió masivamente el caudal de ambos ríos para sostener grandes proyectos de irrigación destinados al cultivo de algodón y arroz, lo que cortó prácticamente el suministro hídrico al lago. El resultado fue una regresión sin precedentes: para 2007 el cuerpo de agua había perdido más del 90 % de su volumen original y se había fragmentado en cuencas separadas.

En la actualidad, el Mar de Aral prácticamente ha desaparecido en su porción sur. El *Small Aral* (Pequeño Mar de Aral, porción norte), contenido parcialmente gracias a la presa Kok-Aral construida en 2005, es el único remanente que muestra indicios de recuperación. El antiguo lecho del lago ha dado lugar al **Desierto de Aralkum**, uno de los desiertos más jóvenes del planeta, caracterizado por extensas costras de sal, arenas deflacionadas y vegetación halófila dispersa. Las consecuencias sobre el clima regional, la salud pública y la economía local han sido documentadas como uno de los peores desastres ambientales antropogénicos de la historia reciente.

1.2. Evento específico de análisis

Para este proyecto se analiza la transformación de la cobertura terrestre en la cuenca del Mar de Aral mediante imágenes multiespectrales Sentinel-2 L2A adquiridas entre el **1 de junio de 2025 y el 29 de septiembre de 2025**. Las escenas fueron seleccionadas desde Copernicus Browser con un umbral máximo de nubosidad del 5 %. Este período coincide con la temporada estival de Asia Central, caracterizada por alta disponibilidad de radiación solar y una mayor separabilidad espectral entre las coberturas de agua, sales, arena y vegetación.

Cuadro 1: Ficha de identificación del evento de estudio

Campo	Descripción
Evento	Desecación progresiva y transformación de la cobertura del suelo en la cuenca del Mar de Aral
Naturaleza	Desastre ambiental antropogénico de desarrollo lento (<i>slow-onset disaster</i>)
Período de análisis	1 de junio de 2025 – 30 de septiembre de 2025
Escena de referencia	Imagen Sentinel-2 L2A de baja nubosidad (<5%), julio de 2025
Relevancia temática	Cambio de uso del suelo, degradación hídrica, desertificación, salinización
Objetivo GeoAI	Clasificación supervisada multi-clase con comparación de cinco arquitecturas de ML

1.3. Justificación de la selección

La elección de esta zona de estudio responde a tres razones concretas. En primer lugar, la cuenca presenta al menos cinco tipos de cobertura espectralmente distinguibles (agua residual, costras salinas, arena, vegetación halófila y suelo mixto en transición), lo que permite construir un conjunto de entrenamiento rico y representativo. En segundo lugar, la magnitud del fenómeno, que abarca cientos de kilómetros cuadrados de cambio superficial, garantiza que la resolución espacial de Sentinel-2 (10 a 20 m) capture fielmente cada categoría. En tercer lugar, el archivo de datos Copernicus mantiene cobertura sistemática de la región con periodicidad de cinco días, y la baja presencia de nubes durante el verano de Asia Central asegura la disponibilidad de imágenes utilizables a lo largo de todo el período seleccionado.

2. Área de Estudio y Límites Espaciales

2.1. Descripción geográfica

El Mar de Aral se encuentra en el interior de Asia Central, aproximadamente entre los paralelos 43° y 47° de latitud norte y los meridianos 58° y 62° de longitud este, a unos 300 km al este del Mar Caspio. El área de estudio definida para este proyecto incluye la totalidad de la cuenca seca, los remanentes hídricos del Small Aral y las zonas de transición ecológica que rodean el antiguo lecho lacustre, garantizando la captura de todas las clases de cobertura relevantes.


2.2. Extensión y bounding box

Cuadro 2: Coordenadas de la Región de Interés (ROI), datum WGS84

Límite	Coordenada	Valor
Latitud norte	$\phi_{\text{máx}}$	46.90° N
Latitud sur	$\phi_{\text{mín}}$	43.50° N
Longitud oeste	$\lambda_{\text{mín}}$	57.50° E
Longitud este	$\lambda_{\text{máx}}$	62.00° E
Extensión aproximada	$\approx 380 \text{ km (E-O)} \times 380 \text{ km (N-S)}$	
Área total del bounding box	$\approx 144.400 \text{ km}^2$	

2.3. Sistema de referencia de coordenadas

Para el procesamiento ráster y la exportación del producto final se utilizará el sistema **WGS84 / UTM Zona 41N** (EPSG: 32641), que cubre íntegramente la extensión de la ROI y minimiza la distorsión en las medidas de área. Para la digitalización de polígonos y la visualización cartográfica se empleará el sistema geográfico **WGS84** (EPSG: 4326).



Región de interés (ROI) utilizada en el proyecto sobre la cuenca del Mar de Aral. La visualización corresponde a imágenes Sentinel-2 L2A en color natural (True Color: bandas B4, B3 y B2) para el período comprendido entre el 1 de junio y el 29 de septiembre de 2025, obtenidas desde Copernicus Browser.

Visualización compartida de Copernicus Browser:

<https://link.dataspace.copernicus.eu/flbb>

3. Metadatos de Imágenes de Satélite

3.1. Plataforma y sensor

Las imágenes utilizadas en este proyecto provienen de la misión **Sentinel-2** de la Agencia Espacial Europea (ESA), dentro del programa Copernicus. La constelación está compuesta por los satélites Sentinel-2A y Sentinel-2B, equipados con el instrumento **MSI** (*MultiSpectral Instrument*), que opera en modo *pushbroom* capturando la radiación solar reflejada por la superficie terrestre. La combinación de ambos satélites produce un tiempo de revisita de cinco días sobre cualquier punto del globo.

Cuadro 3: Especificaciones técnicas del sensor Sentinel-2 MSI

Parámetro	Valor
Misión	Sentinel-2 (ESA Copernicus Programme)
Satélites	Sentinel-2A / Sentinel-2B
Sensor	MultiSpectral Instrument (MSI)
Nivel de procesamiento	L2A — Reflectancia de superficie (Bottom of Atmosphere)
Herramienta de corrección atmosférica	Sen2Cor
Periodicidad de revisita	5 días (constelación) / 10 días (satélite individual)
Resolución radiométrica	12 bits (0 – 4095 niveles digitales)
Ancho de franja	290 km
Altitud orbital	≈ 786 km
Fuente de descarga	Copernicus Data Space Ecosystem (https://dataspace.copernicus.eu)

Cuadro 4: Metadatos de la visualización utilizada para la delimitación de la ROI

Parámetro	Valor
Plataforma	Copernicus Browser
Misión	Sentinel-2 L2A
Sensor	MSI (MultiSpectral Instrument)
Período de visualización	2025-06-01 a 2025-09-29
Composición espectral	True Color (B4, B3, B2)
Cobertura nubosa máxima	5 %
Área aproximada de la ROI	94 079.42 km²
Fuente	https://link.dataspace.copernicus.eu/flbb

3.2. Bandas espectrales y resolución espacial

El sensor MSI captura 13 bandas espectrales distribuidas en tres resoluciones espaciales: cuatro bandas a 10 m, seis bandas a 20 m y tres bandas a 60 m. Para este proyecto se emplean diez bandas, excluyendo las tres de 60 m (B1, B9, B10) orientadas a la corrección atmosférica, que no aportan información de cobertura superficial directa.

Cuadro 5: Bandas Sentinel-2 seleccionadas para el proyecto

Banda	Nombre	λ central (nm)	Res. (m)	Relevancia temática
B2	Azul	490	10	Reflexión hídrica; profundidad de agua
B3	Verde	560	10	Calidad del agua; vigor vegetal
B4	Rojo	665	10	Absorción de clorofila; suelo desnudo
B5	Red Edge 1	705	20	Transición vegetación–suelo salino
B6	Red Edge 2	740	20	Estrés vegetal; detección de salinidad
B7	Red Edge 3	783	20	Biomasa; contenido de agua en hoja
B8	NIR	842	10	NDVI; separación agua–vegetación
B8A	NIR estrecho	865	20	Alta precisión en límite agua–tierra
B11	SWIR-1	1610	20	Humedad de suelo; detección de sales
B12	SWIR-2	2190	20	Minerales arcillosos; costras salinas

Nota: Las bandas de 20 m (B5, B6, B7, B8A, B11, B12) serán remuestreadas a 10 m mediante interpolación bilineal antes de la extracción de píxeles, para que todas las columnas del dataset compartan la misma resolución espacial.

3.3. Índices espectrales derivados

Además de los valores de reflectancia por banda, se calcularán cuatro índices espectrales que permiten enfatizar características específicas de cada cobertura y enriquecer el espacio de características para los modelos:

Cuadro 6: Índices espectrales derivados

Índice	Nombre completo	Fórmula y utilidad
NDVI	Normalized Difference Vegetation Index	$(B8 - B4) / (B8 + B4)$ — Cuantifica el vigor de la vegetación.
NDWI	Normalized Difference Water Index	$(B3 - B8) / (B3 + B8)$ — Delimita extensión de cuerpos de agua.
NDSI	Normalized Difference Salinity Index	$(B11 - B8) / (B11 + B8)$ — Identifica zonas con alta concentración de sales.
BSI	Bare Soil Index	$[(B11 + B4) - (B8 + B2)] / [(B11 + B4) + (B8 + B2)]$ — Resalta suelo desnudo y costras minerales.

4. Creación del Dataset de Entrenamiento

4.1. Clases de cobertura del suelo

A partir del análisis visual de la imagen seleccionada y de la bibliografía disponible sobre el Mar de Aral, se definen cinco clases de cobertura para el entrenamiento supervisado. Estas categorías son espectralmente diferenciables en las bandas de Sentinel-2 y reflejan los distintos estadios de degradación ambiental presentes en la cuenca:

Cuadro 7: Clases de cobertura y códigos de etiqueta

Código	Clase	Descripción
1	Agua	Remanentes hídricos del Small Aral (norte) y cualquier espejo de agua en el lecho sur
2	Playa de sal	Costras salinas (<i>solonchak</i>) expuestas tras el retroceso del nivel de agua
3	Suelo arenoso	Arenas de playa deflacionadas y dunas activas del antiguo lecho lacustre (Aralkum)
4	Vegetación	Plantas halófitas (<i>Salsola</i> , <i>Tamarix</i>) y praderas irrigadas en zonas perimetrales
5	Suelo mixto	Zonas de interdigitación entre suelo salino, arena y material fino

4.2. Proceso de digitalización de polígonos

Los polígonos de entrenamiento se digitalizarán manualmente en QGIS usando como referencia la imagen Sentinel-2 en composición en falso color (B8–B4–B3), complementada con la

capa base de Google Satellite. Se seguirán los siguientes criterios durante la digitalización:

- Cada polígono debe contener únicamente píxeles de una sola clase, evitando zonas de mezcla o bordes difusos entre categorías.
- Los polígonos de cada clase deben distribuirse en distintas zonas de la ROI para capturar la variabilidad espectral intraclase.
- El tamaño mínimo de cada polígono equivale a 3×3 píxeles (900 m^2 a resolución de 10 m) para reducir el efecto de borde del ráster.
- Se busca un mínimo de 500 píxeles por clase y una proporción máxima de 3:1 entre la clase más representada y la menos representada, para evitar sesgos en el entrenamiento.

4.3. Estructura del archivo TSV

El dataset de entrenamiento se exportará como archivo de texto separado por tabulaciones (`.tsv`). Cada fila corresponde a un píxel individual y contiene las siguientes columnas:

Cuadro 8: Estructura del archivo TSV de entrenamiento

Nº	Columna	Tipo	Descripción
1	Latitude	float64	Latitud del centroide del píxel (WGS84, grados decimales)
2	Longitude	float64	Longitud del centroide del píxel (WGS84, grados decimales)
3	B2	float32	Reflectancia de superficie — Banda Azul (490 nm)
4	B3	float32	Reflectancia de superficie — Banda Verde (560 nm)
5	B4	float32	Reflectancia de superficie — Banda Roja (665 nm)
6	B5	float32	Reflectancia de superficie — Red Edge 1 (705 nm)
7	B6	float32	Reflectancia de superficie — Red Edge 2 (740 nm)
8	B7	float32	Reflectancia de superficie — Red Edge 3 (783 nm)
9	B8	float32	Reflectancia de superficie — NIR (842 nm)
10	B8A	float32	Reflectancia de superficie — NIR estrecho (865 nm)
11	B11	float32	Reflectancia de superficie — SWIR-1 (1610 nm)
12	B12	float32	Reflectancia de superficie — SWIR-2 (2190 nm)
13	class_id	int8	Código entero de la clase (1–5, ver Tabla 5)
14	class_name	str	Etiqueta textual de la clase

4.4. Flujo de trabajo y herramientas

1. **Descarga:** Obtención del producto Sentinel-2 L2A desde Copernicus Data Space Ecosystem (<https://dataspace.copernicus.eu>), filtrando por fecha y cobertura nubosa inferior al 5 %.

2. **Preparación en QGIS:** Composición del *stack* multibanda, carga de capa base de referencia y digitalización de polígonos de entrenamiento exportados en formato GeoPackage (.gpkg).
3. **Extracción en Python:** Uso de rasterio para la lectura de las bandas ráster y de geopandas para la intersección entre los polígonos de entrenamiento y el ráster. Cada píxel contenido en un polígono se convierte en una fila del dataset.
4. **Exportación:** El dataframe resultante se exporta con pandas al formato .tsv con separador de tabulación y codificación UTF-8.
5. **Control de calidad:** Verificación del conteo de píxeles por clase, ausencia de valores nulos y rango válido de reflectancias (0.0 – 1.0 para el nivel L2A).

5. Cronograma de Actividades — Fase 1

Cuadro 9: Plan de trabajo Semana 1 — sigmasboys

Día(s)	Actividad	Responsable(s)
1 – 2	Revisión bibliográfica del Mar de Aral, selección del período de análisis y definición de clases de cobertura	Todos
2 – 3	Descarga y verificación del producto Sentinel-2 L2A desde Copernicus Data Space	Joshua / David
3 – 4	Digitalización de polígonos de entrenamiento en QGIS y validación visual de pureza espectral	Juan Diego / Joan
4 – 5	Desarrollo del script de extracción ráster–vector y generación del archivo TSV	Joshua / David
5 – 7	Control de calidad del dataset, estadísticas descriptivas por clase y redacción del informe de la Fase 1	Todos

6. Correcciones y Ajustes Realizados

Durante el desarrollo del proyecto se realizaron múltiples correcciones y ajustes metodológicos con base en las observaciones realizadas por el docente. Estas modificaciones permitieron mejorar la calidad del dataset, optimizar el proceso de entrenamiento y asegurar la coherencia metodológica del pipeline de clasificación supervisada.

6.1. Ajustes en la Construcción del Dataset

Inicialmente se habían definido regiones de entrenamiento demasiado extensas, lo que ocasionaba una cantidad excesiva de píxeles de entrenamiento y un desbalance potencial en el procesamiento de los modelos. Debido a esto, se replanteó la estrategia de selección de muestras, utilizando múltiples polígonos pequeños y homogéneos para cada clase.

Adicionalmente, se estableció como criterio mínimo contar con al menos 2000 píxeles por clase y un mínimo total de 10000 píxeles dentro del dataset final, garantizando así una representación adecuada de cada categoría utilizada en el entrenamiento.

6.2. Corrección de Atributos de Clasificación

Se modificó la estructura de la capa vectorial de entrenamiento para utilizar únicamente el atributo:

`class_name`

eliminando identificadores adicionales como campos `id`, con el fin de simplificar el procesamiento y mantener compatibilidad directa con el pipeline de Machine Learning desarrollado en Python.

6.3. Selección Temporal de Imágenes

Se decidió trabajar únicamente con una única fecha de adquisición Sentinel-2 para evitar inconsistencias espectrales asociadas a cambios temporales, iluminación, humedad o variaciones atmosféricas entre diferentes escenas satelitales.

Esto permitió mantener consistencia radiométrica durante todo el proceso de extracción de píxeles y entrenamiento supervisado.

6.4. Eliminación de Índices Espectrales

Inicialmente se contempló el uso de índices espectrales; sin embargo, siguiendo las recomendaciones del docente, se decidió trabajar exclusivamente con las bandas espectrales originales de Sentinel-2.

Por tanto, el dataset final fue construido únicamente a partir de las bandas multiespectrales disponibles en el stack generado, evitando la incorporación de índices derivados que pudieran introducir redundancia o complejidad adicional en el análisis.

6.5. Organización y Repositorio

Finalmente, todos los archivos asociados al proyecto, incluyendo scripts, datasets, resultados y documentación, fueron organizados y preparados para su integración dentro del repositorio correspondiente del proyecto.

““latex id="kzwrna"

7. Fase 2 - Construcción del Dataset y Extracción de la Zona de Estudio

La segunda fase del proyecto estuvo enfocada en la preparación de los datos de entrada para el proceso de clasificación supervisada. Esta etapa incluyó la selección de la escena satelital Sentinel-2, la extracción de la zona de estudio, la construcción del stack multibanda y la generación de las muestras de entrenamiento utilizadas posteriormente en los modelos de Machine Learning.

Extracción y Preparación de la Zona de Estudio

7.1. Selección de la Imagen Satelital

La imagen utilizada en el proyecto fue obtenida desde la plataforma Copernicus Browser, perteneciente al programa Sentinel de la Agencia Espacial Europea (ESA). Para el desarrollo del análisis se seleccionó una escena Sentinel-2 nivel L2A, correspondiente a productos con corrección atmosférica aplicada.

La selección de una única fecha de adquisición permitió mantener consistencia espectral y radiométrica durante todo el proceso de clasificación, evitando variaciones temporales relacionadas con cambios ambientales, humedad, nubosidad o diferencias de iluminación.

La escena descargada correspondió a:

- Satélite: Sentinel-2
- Producto: Level-2A (L2A)
- Tipo de resolución utilizada: 20 metros
- Plataforma de descarga: Copernicus Browser

7.2. Definición de la Zona de Estudio

Posteriormente se realizó la delimitación de la zona de interés correspondiente al área seleccionada dentro del Mar de Aral. Esta región fue escogida debido a la presencia de diferentes

coberturas superficiales claramente diferenciables espectralmente, tales como cuerpos de agua, playas salinas y zonas arenosas.

La extracción de la zona de estudio se realizó utilizando QGIS, permitiendo trabajar únicamente sobre el área relevante del proyecto y reduciendo el volumen de procesamiento asociado al raster completo descargado desde Copernicus.




Figura 1: Zona de estudio extraída desde Copernicus Browser para el desarrollo del proyecto.

7.3. Bandas Espectrales Utilizadas

Para el proceso de clasificación supervisada se trabajó exclusivamente con las bandas espectrales originales de Sentinel-2, evitando el uso de índices espectrales derivados, siguiendo las recomendaciones metodológicas establecidas para el proyecto.

Las bandas utilizadas fueron seleccionadas debido a su relevancia en la diferenciación de coberturas terrestres y características superficiales presentes en la zona de estudio.

Las bandas utilizadas en el stack multibanda fueron:

Banda	Descripción	Resolución
B2	Azul	20 m
B3	Verde	20 m
B4	Rojo	20 m
B5	Red Edge 1	20 m
B6	Red Edge 2	20 m
B7	Red Edge 3	20 m
B8A	Infrarrojo Cercano Estrecho	20 m
B11	Infrarrojo de Onda Corta 1	20 m
B12	Infrarrojo de Onda Corta 2	20 m

Cuadro 10: Bandas espectrales Sentinel-2 utilizadas en el proyecto.

7.4. Construcción del Stack Multibanda

Una vez descargadas las bandas necesarias, se procedió a construir un raster multibanda utilizando las herramientas de procesamiento raster de QGIS. Este procedimiento permitió consolidar todas las bandas espectrales en un único archivo raster, facilitando el posterior procesamiento en Python y los algoritmos de Machine Learning.

El stack multibanda final fue exportado en formato GeoTIFF (.tif), permitiendo compatibilidad directa con librerías geoespaciales como Rasterio y GDAL.

El raster generado presentó las siguientes características generales:

- Formato: GeoTIFF
- Tipo de dato: uint16
- Número de bandas: 9
- Dimensiones aproximadas: 5490 x 5490 píxeles
- Sistema de referencia espacial consistente con Sentinel-2

7.5. Generación de Muestras de Entrenamiento

Posteriormente se realizó la construcción manual de muestras supervisadas mediante polígonos de entrenamiento creados en QGIS. Estas muestras fueron utilizadas para representar de forma homogénea las diferentes clases presentes en la zona de estudio.

Las clases seleccionadas fueron:

- Agua
- Playa_sal
- Arena

Durante esta etapa se aplicaron correcciones metodológicas para evitar polígonos excesivamente grandes o mezclas entre clases, garantizando que cada región de entrenamiento representara únicamente una cobertura homogénea.

Finalmente, las muestras fueron exportadas en formato GeoPackage (.gpkg) utilizando exclusivamente el atributo:

`class_name`

el cual fue posteriormente utilizado en el pipeline de Machine Learning para la extracción automática de píxeles de entrenamiento. ““

7.6. Selección y Preparación de Bandas Espectrales

Después de definir la zona de estudio, se realizó la selección de las bandas espectrales Sentinel-2 que serían utilizadas dentro del proceso de clasificación supervisada. La selección de bandas fue realizada considerando aquellas con mayor capacidad para diferenciar cuerpos de agua, zonas salinas y superficies arenosas presentes en el área analizada.

Inicialmente, las bandas descargadas desde Copernicus se encontraban almacenadas de forma independiente en formato JPEG2000 (.jp2), por lo que fue necesario realizar un proceso de organización y consolidación dentro de QGIS.

Debido a la necesidad de mantener consistencia espacial entre todas las capas utilizadas, únicamente se seleccionaron bandas con resolución espacial de 20 metros, evitando procesos adicionales de remuestreo que pudieran alterar los valores espectrales originales.

Las bandas finalmente seleccionadas fueron:

- B2 - Azul
- B3 - Verde
- B4 - Rojo
- B5 - Red Edge 1
- B6 - Red Edge 2
- B7 - Red Edge 3
- B8A - Infrarrojo Cercano Estrecho
- B11 - Infrarrojo de Onda Corta 1
- B12 - Infrarrojo de Onda Corta 2

Estas bandas permitieron capturar diferentes respuestas espectrales asociadas a humedad, reflectancia superficial, minerales, salinidad y características del terreno presentes dentro del Mar de Aral.

7.7. Construcción del Raster Multibanda

Una vez organizadas las bandas espectrales, se procedió a construir un raster multibanda utilizando las herramientas de procesamiento raster disponibles en QGIS.

El procedimiento consistió en combinar todas las bandas seleccionadas dentro de un único archivo raster multiespectral. Este proceso permitió consolidar toda la información espectral en una sola estructura de datos compatible con los algoritmos de Machine Learning implementados posteriormente en Python.

Para la generación del raster multibanda se utilizaron herramientas equivalentes a:

- Build Virtual Raster (VRT)
- Translate (Convert Format)

Inicialmente se construyó un raster virtual (.vrt) con el objetivo de verificar la correcta alineación espacial y espectral de las bandas. Posteriormente, el raster fue exportado a formato GeoTIFF (.tif), obteniendo el archivo final utilizado durante todo el proyecto.

El raster multibanda generado presentó las siguientes características:

- Formato final: GeoTIFF (.tif)
- Número total de bandas: 9
- Resolución espacial: 20 metros
- Tipo de dato: uint16
- Dimensiones aproximadas: 5490 x 5490 píxeles

La consolidación del stack multibanda facilitó significativamente el procesamiento automatizado mediante Rasterio y Scikit-Learn, permitiendo extraer información espectral de forma eficiente durante el entrenamiento supervisado.




Figura 2: Raster multibanda construido a partir de las bandas Sentinel-2 seleccionadas.

7.8. Preparación de Polígonos de Entrenamiento

Posteriormente se realizó la construcción manual de los polígonos de entrenamiento supervisado dentro de QGIS. Estas regiones fueron utilizadas para representar muestras homogéneas de cada clase presente en la zona de estudio.

La preparación de polígonos constituyó una de las etapas más importantes del proyecto, debido a que la calidad de las muestras influye directamente en el desempeño de los modelos de Machine Learning.

Inicialmente se habían definido polígonos demasiado extensos, lo que ocasionó la extracción de una cantidad excesiva de píxeles de entrenamiento. Como consecuencia, se realizó una corrección metodológica consistente en reemplazar grandes regiones por múltiples polígonos pequeños y homogéneos distribuidos en diferentes zonas de la imagen.

Cada polígono fue construido siguiendo los siguientes criterios:

- Representar únicamente una sola clase.
- Evitar bordes o zonas de transición.
- Seleccionar regiones espectralmente homogéneas.
- Distribuir muestras en diferentes sectores de la imagen.
- Evitar mezclar agua, arena y sal dentro de un mismo polígono.

Las clases utilizadas para el entrenamiento fueron:

- Agua
- Playa_sal

- Arena

Cada polígono fue almacenado dentro de una capa vectorial GeoPackage (`training.gpkg`) utilizando el atributo:

```
class_name
```

el cual permitió asociar automáticamente cada píxel extraído con su clase correspondiente durante el proceso de construcción del dataset supervisado.

Finalmente, los polígonos fueron utilizados como entrada del pipeline automatizado desarrollado en Python, permitiendo extraer millones de valores espectrales correspondientes a las bandas Sentinel-2 seleccionadas.

8. Entrenamiento y Evaluación de Modelos de Machine Learning

Fase 3 - Clasificación Supervisada y Evaluación de Modelos

La tercera fase del proyecto estuvo enfocada en la construcción del pipeline de clasificación supervisada utilizando técnicas de Machine Learning aplicadas sobre información multiespectral Sentinel-2.

Para esta etapa se desarrolló un flujo automatizado en Python orientado a la extracción de píxeles, generación del dataset supervisado, entrenamiento de múltiples clasificadores y evaluación comparativa de desempeño.

El pipeline principal fue implementado en el archivo:

```
sentinel2_supervised_pipeline.py
```

mientras que una versión optimizada para reutilizar datasets previamente exportados fue implementada en:

```
train_from_tsv.py
```

8.1. Construcción del Dataset Supervisado

El flujo de entrenamiento inició con la lectura de los polígonos de entrenamiento almacenados en formato GeoPackage (`.gpkg`). Durante esta etapa se verificó la existencia de la columna de clases y de las geometrías necesarias para el proceso de extracción supervisada.

Posteriormente, el pipeline realizó múltiples procesos automáticos de validación espacial y limpieza geométrica, incluyendo:

- Eliminación de geometrías vacías.

- Corrección de polígonos inválidos.
- Reproyección automática al sistema de referencia espacial del raster.
- Verificación de consistencia espacial entre raster y vector.

Una vez validados los polígonos, se procedió a extraer los píxeles correspondientes desde el raster multibanda Sentinel-2 mediante operaciones de enmascaramiento raster-vectorial.

Cada píxel extraído fue convertido en una fila dentro del dataset final, mientras que cada banda espectral representó una característica de entrada para los modelos de Machine Learning.

El dataset generado incluyó:

- Valores espectrales de las bandas Sentinel-2.
- Etiqueta de clase correspondiente.
- Eliminación de valores nodata.
- Filtrado de datos no válidos o infinitos.

Finalmente, el dataset completo fue exportado en formato TSV (.tsv) para facilitar reproducibilidad y reutilización posterior.

8.2. División de Datos Train/Test

Después de la construcción del dataset supervisado, las clases fueron codificadas mediante el uso de:

LabelEncoder

permitiendo transformar las etiquetas categóricas en valores numéricos compatibles con Scikit-Learn.

Posteriormente, el dataset fue dividido en conjuntos de entrenamiento y prueba utilizando un *split* estratificado. Esta estrategia permitió conservar la distribución original de clases en ambos subconjuntos, evitando sesgos durante la evaluación de desempeño.

La división fue realizada utilizando:

- 70 % para entrenamiento.
- 30 % para validación y prueba.
- Semilla aleatoria fija para reproducibilidad experimental.

8.3. Modelos de Machine Learning Utilizados

El pipeline implementó múltiples algoritmos clásicos de clasificación supervisada con el objetivo de comparar desempeño y seleccionar el modelo más robusto para el problema planteado.

Los modelos entrenados fueron:

- Decision Tree
- Support Vector Machine (SVM)
- K-Nearest Neighbors (KNN)
- Gaussian Naive Bayes
- Multi-Layer Perceptron (MLP)
- Random Forest

Para los modelos sensibles a escalamiento de variables, se incorporó:

`StandardScaler`

dentro de un pipeline de procesamiento, permitiendo normalizar automáticamente los valores espectrales antes del entrenamiento.

Adicionalmente, el sistema incluyó soporte opcional para:

`GridSearchCV`

permitiendo realizar ajuste automático de hiperparámetros y optimización de desempeño mediante validación cruzada.

8.4. Métricas de Evaluación

La evaluación de desempeño fue realizada utilizando múltiples métricas estándar de clasificación multiclase, con el objetivo de analizar tanto precisión global como equilibrio entre categorías.

Las métricas calculadas fueron:

- Accuracy
- Precision Macro
- Recall Macro
- F1 Macro
- Coeficiente Kappa de Cohen

Estas métricas permitieron evaluar la capacidad de generalización de cada clasificador y analizar el comportamiento frente a posibles confusiones espectrales entre clases similares.

Además, para cada modelo entrenado se generaron:

- Matrices de confusión.
- Reportes completos de clasificación.
- Gráficas comparativas de desempeño.

8.5. Resultados Experimentales

Durante el proceso de entrenamiento se evaluaron múltiples algoritmos de clasificación supervisada con el objetivo de comparar desempeño y seleccionar el modelo más adecuado para la clasificación multiespectral Sentinel-2.

Cada modelo fue entrenado utilizando el dataset supervisado construido a partir de los píxeles extraídos desde los polígonos de entrenamiento. Posteriormente, los modelos fueron evaluados utilizando el conjunto de prueba generado mediante división estratificada.

El proceso completo generó múltiples salidas experimentales, incluyendo métricas de desempeño, matrices de confusión, rankings comparativos y modelos serializados.

8.6. Resumen del Dataset Utilizado

El pipeline reportó la siguiente configuración experimental:

- Número total de características espectrales: 9 bandas Sentinel-2.
- Clases detectadas: Arena, Agua y Playa_sal.
- Tamaño máximo utilizado por clase: 100000 píxeles.
- Total de muestras utilizadas: 200000 píxeles.
- Conjunto de entrenamiento: 150000 muestras.
- Conjunto de prueba: 50000 muestras.

8.7. Métricas Comparativas de los Modelos

Los modelos entrenados fueron evaluados utilizando Accuracy, Precision Macro, Recall Macro, F1 Macro y coeficiente Kappa de Cohen.

Los resultados obtenidos fueron los siguientes:

Modelo	Accuracy	Precision	Recall	F1 Macro	Kappa
MLPClassifier	0.8422	0.8425	0.8422	0.8421	0.6844
RandomForest	0.8376	0.8385	0.8376	0.8374	0.6752
KNN	0.8285	0.8295	0.8285	0.8284	0.6571
SVM	0.8097	0.8207	0.8097	0.8081	0.6195
DecisionTree	0.7845	0.7845	0.7845	0.7845	0.5690
GaussianNB	0.7225	0.7655	0.7225	0.7108	0.4450

Cuadro 11: Comparación de desempeño entre los modelos de clasificación supervisada.

8.8. Selección del Mejor Modelo

A partir de las métricas obtenidas, el modelo con mejor desempeño general fue:

MLPClassifier

Este modelo obtuvo los valores más altos tanto en F1 Macro como en coeficiente Kappa, indicando un mejor equilibrio entre precisión y capacidad de generalización.

El uso de una arquitectura Multi-Layer Perceptron permitió capturar relaciones no lineales complejas entre las bandas espectrales Sentinel-2, mejorando la separación entre clases espectralmente similares.

8.9. Matrices de Confusión

Para cada uno de los modelos entrenados se generó una matriz de confusión con el objetivo de analizar detalladamente los errores de clasificación entre clases.

Estas matrices permitieron identificar:

- Clases con mayor tasa de confusión.
- Errores sistemáticos de clasificación.
- Capacidad discriminativa de cada modelo.
- Balance entre falsos positivos y falsos negativos.

A continuación se presentan los espacios reservados para las matrices de confusión generadas durante el entrenamiento experimental.

8.9.1. Matriz de Confusión - Decision Tree




Figura 3: Matriz de confusión obtenida para el modelo Decision Tree.

8.9.2. Matriz de Confusión - SVM




Figura 4: Matriz de confusión obtenida para el modelo SVM.

8.9.3. Matriz de Confusión - KNN




Figura 5: Matriz de confusión obtenida para el modelo KNN.

8.9.4. Matriz de Confusión - GaussianNB




Figura 6: Matriz de confusión obtenida para el modelo GaussianNB.

8.9.5. Matriz de Confusión - MLPClassifier




Figura 7: Matriz de confusión obtenida para el modelo MLPClassifier.

8.9.6. Matriz de Confusión - Random Forest




Figura 8: Matriz de confusión obtenida para el modelo Random Forest.

8.10. Archivos y Resultados Generados

El pipeline generó automáticamente múltiples artefactos de salida asociados al proceso experimental.

Entre los principales archivos obtenidos se encuentran:

- Dataset supervisado en formato TSV.
- Ranking comparativo de modelos.
- Métricas exportadas en CSV.
- Matrices de confusión en PNG.
- Modelo final serializado en formato joblib.
- Reportes automáticos de clasificación.
- Gráficas comparativas de desempeño.

Estos resultados permitieron garantizar trazabilidad experimental, reproducibilidad y documentación completa del proceso de clasificación supervisada.

9. Conclusiones de la Fase de Entrenamiento y Clasificación Supervisada

La fase de entrenamiento y evaluación de modelos permitió validar la viabilidad del uso de técnicas de Machine Learning aplicadas sobre imágenes multiespectrales Sentinel-2 para tareas de clasificación supervisada en entornos de percepción remota.

Uno de los principales resultados obtenidos fue la construcción exitosa de un pipeline automatizado capaz de integrar procesamiento geoespacial, extracción de píxeles, generación de datasets supervisados, entrenamiento de modelos y evaluación comparativa dentro de un único flujo reproducible.

Durante el proceso experimental se evidenció la importancia de la calidad de las muestras de entrenamiento. La corrección de polígonos excesivamente grandes y la utilización de regiones homogéneas permitió reducir ruido espectral y mejorar significativamente el comportamiento de los clasificadores.

Asimismo, se comprobó que el uso exclusivo de bandas espectrales originales de Sentinel-2 fue suficiente para obtener resultados competitivos, evitando la necesidad de incorporar índices espectrales adicionales.

En términos de desempeño, los modelos basados en aprendizaje no lineal obtuvieron mejores resultados frente a clasificadores más simples. Particularmente, el modelo `MLPClassifier` presentó el mejor equilibrio entre precisión, capacidad de generalización y estabilidad, alcanzando los mayores valores de F1 Macro y coeficiente Kappa dentro del conjunto experimental.

Los resultados también demostraron que algoritmos como Random Forest y KNN poseen un desempeño robusto para problemas de clasificación multiespectral, mientras que modelos probabilísticos más simples, como Gaussian Naive Bayes, presentaron mayores limitaciones frente a clases con respuestas espectrales similares.

Otro aspecto relevante fue la capacidad del pipeline para producir automáticamente múltiples artefactos de validación y documentación, incluyendo métricas, rankings, modelos serializados y reportes exportables, fortaleciendo la reproducibilidad experimental y la trazabilidad metodológica del proyecto.

En términos generales, esta etapa permitió consolidar una metodología robusta para clasificación supervisada en GeoAI, integrando herramientas de percepción remota, análisis geoespacial y aprendizaje automático dentro de un flujo moderno y escalable para análisis de imágenes satelitales Sentinel-2.

10. Conclusión

Esta primera fase sienta las bases conceptuales y de datos del proyecto. La cuenca del Mar de Aral ofrece un escenario de alta relevancia ambiental que reúne las condiciones ideales para el análisis comparativo de arquitecturas de aprendizaje automático: diversidad de coberturas del suelo, magnitud espacial del fenómeno y disponibilidad continua de imágenes satelitales de calidad. La delimitación precisa de la ROI, la identificación de las clases de cobertura y la construcción rigurosa del dataset TSV son los pasos que garantizarán la validez y reproducibilidad de los resultados en las fases siguientes.

Referencias

- [1] Micklin, P. (2016). The future of the Aral Sea: hope and despair. *The Geographical Journal*, 182(2), 116–127. <https://doi.org/10.1111/geoj.12174>
- [2] ESA. (2025). *Earth from Space: The shrinking Aral Sea*. European Space Agency. Copernicus Sentinel data (2025), procesado por ESA. https://www.esa.int/ESA_Multimedia/Images/2025/04/Earth_from_Space_The_shrinking_Aral_Sea
- [3] ESA. (2024). *Sentinel-2 MSI — User Guides: Spatial Resolutions*. Sentinel Online. <https://sentinel.esa.int/web/sentinel/user-guides/sentinel-2-msi/resolutions/spatial>
- [4] ESA. (2024). *Sentinel-2 Auxiliary and Data Product Specification — MSI*. Copernicus EOPF. <https://s2.pages.eopf.copernicus.eu/pdfs-adfs/MSI/index.html>
- [5] NASA Earthdata. (2025). *Sentinel-2 Multispectral Imager (MSI)*. NASA EOSDIS. <https://www.earthdata.nasa.gov/data/instruments/sentinel-2-msi>
- [6] USGS EROS. (2024). *Aral Sea, Kazakhstan and Uzbekistan — EarthShots*. U.S. Geological Survey. <https://eros.usgs.gov/earthshots/aral-sea-kazakhstan-and-uzbekistan>
- [7] UNCCD. (2025). *Witnessing an environmental catastrophe: Reflections from the dried-up Aral Sea*. United Nations Convention to Combat Desertification. <https://www.unccd.int/news-stories/special-feature/witnessing-environmental-catastrophe-reflection>
- [8] Britannica. (2026). *Aral Sea*. Encyclopædia Britannica. Última actualización: 28 de marzo de 2026. <https://www.britannica.com/place/Aral-Sea>
- [9] Gillies, S., et al. (2019). *Rasterio: Geospatial Raster I/O for Python Programmers*. Mapbox. <https://github.com/rasterio/rasterio>
- [10] Jordahl, K., et al. (2021). *GeoPandas v0.9.0*. Zenodo. <https://doi.org/10.5281/zenodo.5573592>
- [11] Main-Knorn, M., et al. (2017). Sen2Cor for Sentinel-2. *Proceedings SPIE 10427, Image and Signal Processing for Remote Sensing XXIII*. <https://doi.org/10.1117/12.2278218>