

**Proyecto Final — Análisis Comparativo de Arquitecturas de
Aprendizaje Automático para el Monitoreo Superficial
Basado en Satélite**

Fases 1, 2, y 3.

Zona de estudio: Mar de Aral (Kazajistán / Uzbekistán)

Período: Junio – Septiembre de 2025

Equipo: *sigmasboys*

Juan Diego Muñoz Angulo

Joan Orduz Chia

Joshua Prieto Zambrano

David Roa Neisa

Repositorio: https://github.com/JoshuaPZz/Emergentes_Proyecto

Bogotá D.C., Colombia

Mayo de 2026

Índice

1. Definición del Evento y Justificación	4
1.1. Contexto general	4
1.2. Evento específico de análisis	4
1.3. Justificación de la selección	5
2. Área de Estudio y Límites Espaciales	5
2.1. Descripción geográfica	5
2.2. Extensión y bounding box	6
2.3. Sistema de referencia de coordenadas	6
3. Metadatos de Imágenes de Satélite	7
3.1. Plataforma y sensor	7
3.2. Bandas espectrales y resolución espacial	8
3.3. Índices espectrales derivados	9
4. Creación del Dataset de Entrenamiento	10
4.1. Clases de cobertura del suelo	10
4.2. Proceso de digitalización de polígonos	10
4.3. Estructura del archivo TSV	11
4.4. Flujo de trabajo y herramientas	11
5. Cronograma de Actividades — Fase 1	12
6. Correcciones y Ajustes Realizados	12
6.1. Ajustes en la Construcción del Dataset	13
6.2. Corrección de Atributos de Clasificación	13
6.3. Selección Temporal de Imágenes	13
6.4. Eliminación de Índices Espectrales	13
6.5. Organización y Repositorio	14
7. Fase 2 - Construcción del Dataset y Extracción de la Zona de Estudio	14
7.1. Selección de la Imagen Satelital	14
7.2. Definición de la Zona de Estudio	14
7.3. Bandas Espectrales Utilizadas	15
7.4. Construcción del Stack Multibanda	16
7.5. Generación de Muestras de Entrenamiento	16
7.6. Selección y Preparación de Bandas Espectrales	17
7.7. Construcción del Raster Multibanda	18

7.8. Preparación de Polígonos de Entrenamiento	19
8. Entrenamiento y Evaluación de Modelos de Machine Learning	22
8.1. Construcción del Dataset Supervisado	22
8.2. División de Datos Train/Test	23
8.3. Modelos de Machine Learning Utilizados	23
8.4. Métricas de Evaluación	24
8.5. Resultados Experimentales	25
8.6. Resumen del Dataset Utilizado	25
8.7. Métricas Comparativas de los Modelos	25
8.8. Selección del Mejor Modelo	26
8.9. Matrices de Confusión	26
8.9.1. Matriz de Confusión - Decision Tree	27
8.9.2. Matriz de Confusión - SVM	28
8.9.3. Matriz de Confusión - KNN	29
8.9.4. Matriz de Confusión - GaussianNB	30
8.9.5. Matriz de Confusión - MLPClassifier	31
8.9.6. Matriz de Confusión - Random Forest	32
8.10. Archivos y Resultados Generados	32
9. Conclusiones de la Fase de Entrenamiento y Clasificación Supervisada	33
10. Fase 3 - Cambios Implementados para la Tercera Entrega (Retroalimentación Fase 2 y Resultados Fase 3)	34
10.1. Redefinición de las Clases de Estudio	34
10.2. Actualización de los Polígonos de Entrenamiento	34
10.3. Distribución Final de Muestras	35
10.4. Entrenamiento y Evaluación de Modelos	36
10.5. Selección del Mejor Modelo	37
10.6. Matrices de Confusión	38
10.7. Visualización del Raster de Entrada	39
10.8. Superposición entre Raster y Polígonos	40
10.9. Organización de Capas en QGIS	41
11. Generación del Mapa Clasificado con SVM	42
11.1. Capas Finales del Proyecto	43
12. Cálculo de Áreas por Clase	44
13. Comparación Visual con Google Maps	45
14. Conclusión	47

14.1. Logros Alcanzados	47
14.2. Selección del Modelo y Generación del Mapa	47
14.3. Cuantificación de Áreas	48
14.4. Validación y Significancia	48
14.5. Trabajo Futuro	48
Referencias	49

1. Definición del Evento y Justificación

1.1. Contexto general

El Mar de Aral fue durante el siglo XX el cuarto lago más grande del mundo, con una superficie aproximada de 68.000 km² y una profundidad media de unos 16 metros. Se ubica en Asia Central, en la frontera entre Kazajistán al norte y Uzbekistán al sur, y era alimentado principalmente por los ríos Amu Daria y Sir Daria. A partir de los años sesenta, el gobierno soviético desvió masivamente el caudal de ambos ríos para sostener grandes proyectos de irrigación destinados al cultivo de algodón y arroz, lo que cortó prácticamente el suministro hídrico al lago. El resultado fue una regresión sin precedentes: para 2007 el cuerpo de agua había perdido más del 90 % de su volumen original y se había fragmentado en cuencas separadas.

En la actualidad, el Mar de Aral prácticamente ha desaparecido en su porción sur. El *Small Aral* (Pequeño Mar de Aral, porción norte), contenido parcialmente gracias a la presa Kok-Aral construida en 2005, es el único remanente que muestra indicios de recuperación. El antiguo lecho del lago ha dado lugar al **Desierto de Aralkum**, uno de los desiertos más jóvenes del planeta, caracterizado por extensas costras de sal, arenas deflacionadas y vegetación halófila dispersa. Las consecuencias sobre el clima regional, la salud pública y la economía local han sido documentadas como uno de los peores desastres ambientales antropogénicos de la historia reciente.

1.2. Evento específico de análisis

Para este proyecto se analiza la transformación de la cobertura terrestre en la cuenca del Mar de Aral mediante imágenes multiespectrales Sentinel-2 L2A adquiridas entre el **1 de junio de 2025 y el 29 de septiembre de 2025**. Las escenas fueron seleccionadas desde Copernicus Browser con un umbral máximo de nubosidad del 5 %. Este período coincide con la temporada estival de Asia Central, caracterizada por alta disponibilidad de radiación solar y una mayor separabilidad espectral entre las coberturas de agua, sales, arena y vegetación.

Cuadro 1: Ficha de identificación del evento de estudio

Campo	Descripción
Evento	Desecación progresiva y transformación de la cobertura del suelo en la cuenca del Mar de Aral
Naturaleza	Desastre ambiental antropogénico de desarrollo lento (<i>slow-onset disaster</i>)
Período de análisis	1 de junio de 2025 – 30 de septiembre de 2025
Escena de referencia	Imagen Sentinel-2 L2A de baja nubosidad (<5%), julio de 2025
Relevancia temática	Cambio de uso del suelo, degradación hídrica, desertificación, salinización
Objetivo GeoAI	Clasificación supervisada multi-clase con comparación de cinco arquitecturas de ML

1.3. Justificación de la selección

La elección de esta zona de estudio responde a tres razones concretas. En primer lugar, la cuenca presenta al menos cinco tipos de cobertura espectralmente distinguibles (agua residual, costras salinas, arena, vegetación halófila y suelo mixto en transición), lo que permite construir un conjunto de entrenamiento rico y representativo. En segundo lugar, la magnitud del fenómeno, que abarca cientos de kilómetros cuadrados de cambio superficial, garantiza que la resolución espacial de Sentinel-2 (10 a 20 m) capture fielmente cada categoría. En tercer lugar, el archivo de datos Copernicus mantiene cobertura sistemática de la región con periodicidad de cinco días, y la baja presencia de nubes durante el verano de Asia Central asegura la disponibilidad de imágenes utilizables a lo largo de todo el período seleccionado.

2. Área de Estudio y Límites Espaciales

2.1. Descripción geográfica

El Mar de Aral se encuentra en el interior de Asia Central, aproximadamente entre los paralelos 43° y 47° de latitud norte y los meridianos 58° y 62° de longitud este, a unos 300 km al este del Mar Caspio. El área de estudio definida para este proyecto incluye la totalidad de la cuenca seca, los remanentes hídricos del Small Aral y las zonas de transición ecológica que rodean el antiguo lecho lacustre, garantizando la captura de todas las clases de cobertura relevantes.


2.2. Extensión y bounding box

Cuadro 2: Coordenadas de la Región de Interés (ROI), datum WGS84

Límite	Coordenada	Valor
Latitud norte	$\phi_{\text{máx}}$	46.90° N
Latitud sur	$\phi_{\text{mín}}$	43.50° N
Longitud oeste	$\lambda_{\text{mín}}$	57.50° E
Longitud este	$\lambda_{\text{máx}}$	62.00° E
Extensión aproximada		$\approx 380 \text{ km (E-O)} \times 380 \text{ km (N-S)}$
Área total del bounding box		$\approx 144.400 \text{ km}^2$

2.3. Sistema de referencia de coordenadas

Para el procesamiento ráster y la exportación del producto final se utilizará el sistema **WGS84 / UTM Zona 41N** (EPSG : 32641), que cubre íntegramente la extensión de la ROI y minimiza la distorsión en las medidas de área. Para la digitalización de polígonos y la visualización cartográfica se empleará el sistema geográfico **WGS84** (EPSG : 4326).



Región de interés (ROI) utilizada en el proyecto sobre la cuenca del Mar de Aral. La visualización corresponde a imágenes Sentinel-2 L2A en color natural (True Color: bandas B4, B3 y B2) para el período comprendido entre el 1 de junio y el 29 de septiembre de 2025, obtenidas desde Copernicus Browser.

Visualización compartida de Copernicus Browser:

<https://link.dataspace.copernicus.eu/flbb>

3. Metadatos de Imágenes de Satélite

3.1. Plataforma y sensor

Las imágenes utilizadas en este proyecto provienen de la misión **Sentinel-2** de la Agencia Espacial Europea (ESA), dentro del programa Copernicus. La constelación está compuesta por los satélites Sentinel-2A y Sentinel-2B, equipados con el instrumento **MSI** (*MultiSpectral Instrument*), que opera en modo *pushbroom* capturando la radiación solar reflejada por la superficie terrestre. La combinación de ambos satélites produce un tiempo de revisita de cinco días sobre cualquier punto del globo.

Cuadro 3: Especificaciones técnicas del sensor Sentinel-2 MSI

Parámetro	Valor
Misión	Sentinel-2 (ESA Copernicus Programme)
Satélites	Sentinel-2A / Sentinel-2B
Sensor	MultiSpectral Instrument (MSI)
Nivel de procesamiento	L2A — Reflectancia de superficie (Bottom of Atmosphere)
Herramienta de corrección atmosférica	Sen2Cor
Periodicidad de revisita	5 días (constelación) / 10 días (satélite individual)
Resolución radiométrica	12 bits (0 – 4095 niveles digitales)
Ancho de franja	290 km
Altitud orbital	≈ 786 km
Fuente de descarga	Copernicus Data Space Ecosystem (https://dataspace.copernicus.eu)

Cuadro 4: Metadatos de la visualización utilizada para la delimitación de la ROI

Parámetro	Valor
Plataforma	Copernicus Browser
Misión	Sentinel-2 L2A
Sensor	MSI (MultiSpectral Instrument)
Período de visualización	2025-06-01 a 2025-09-29
Composición espectral	True Color (B4, B3, B2)
Cobertura nubosa máxima	5 %
Área aproximada de la ROI	94 079.42 km ²
Fuente	https://link.dataspace.copernicus.eu/flbb

3.2. Bandas espectrales y resolución espacial

El sensor MSI captura 13 bandas espectrales distribuidas en tres resoluciones espaciales: cuatro bandas a 10 m, seis bandas a 20 m y tres bandas a 60 m. Para este proyecto se emplean diez bandas, excluyendo las tres de 60 m (B1, B9, B10) orientadas a la corrección atmosférica, que no aportan información de cobertura superficial directa.

Cuadro 5: Bandas Sentinel-2 seleccionadas para el proyecto

Banda	Nombre	λ central (nm)	Res. (m)	Relevancia temática
B2	Azul	490	10	Reflexión hídrica; profundidad de agua
B3	Verde	560	10	Calidad del agua; vigor vegetal
B4	Rojo	665	10	Absorción de clorofila; suelo desnudo
B5	Red Edge 1	705	20	Transición vegetación–suelo salino
B6	Red Edge 2	740	20	Estrés vegetal; detección de salinidad
B7	Red Edge 3	783	20	Biomasa; contenido de agua en hoja
B8	NIR	842	10	NDVI; separación agua–vegetación
B8A	NIR estrecho	865	20	Alta precisión en límite agua–tierra
B11	SWIR-1	1610	20	Humedad de suelo; detección de sales
B12	SWIR-2	2190	20	Minerales arcillosos; costras salinas

Nota: Las bandas de 20 m (B5, B6, B7, B8A, B11, B12) serán remuestreadas a 10 m mediante interpolación bilineal antes de la extracción de píxeles, para que todas las columnas del dataset compartan la misma resolución espacial.

3.3. Índices espectrales derivados

Además de los valores de reflectancia por banda, se calcularán cuatro índices espectrales que permiten enfatizar características específicas de cada cobertura y enriquecer el espacio de características para los modelos:

Cuadro 6: Índices espectrales derivados

Índice	Nombre completo	Fórmula y utilidad
NDVI	Normalized Difference Vegetation Index	$(B8 - B4) / (B8 + B4)$ — Cuantifica el vigor de la vegetación.
NDWI	Normalized Difference Water Index	$(B3 - B8) / (B3 + B8)$ — Delimita extensión de cuerpos de agua.
NDSI	Normalized Difference Salinity Index	$(B11 - B8) / (B11 + B8)$ — Identifica zonas con alta concentración de sales.
BSI	Bare Soil Index	$[(B11 + B4) - (B8 + B2)] / [(B11 + B4) + (B8 + B2)]$ — Resalta suelo desnudo y costras minerales.

4. Creación del Dataset de Entrenamiento

4.1. Clases de cobertura del suelo

A partir del análisis visual de la imagen seleccionada y de la bibliografía disponible sobre el Mar de Aral, se definen cinco clases de cobertura para el entrenamiento supervisado. Estas categorías son espectralmente diferenciables en las bandas de Sentinel-2 y reflejan los distintos estadios de degradación ambiental presentes en la cuenca:

Cuadro 7: Clases de cobertura y códigos de etiqueta

Código	Clase	Descripción
1	Agua	Remanentes hídricos del Small Aral (norte) y cualquier espejo de agua en el lecho sur
2	Playa de sal	Costras salinas (<i>solonchak</i>) expuestas tras el retroceso del nivel de agua
3	Suelo arenoso	Arenas de playa deflacionadas y dunas activas del antiguo lecho lacustre (Aralkum)
4	Vegetación	Plantas halófitas (<i>Salsola</i> , <i>Tamarix</i>) y praderas irrigadas en zonas perimetrales
5	Suelo mixto	Zonas de interdigitación entre suelo salino, arena y material fino

4.2. Proceso de digitalización de polígonos

Los polígonos de entrenamiento se digitalizarán manualmente en QGIS usando como referencia la imagen Sentinel-2 en composición en falso color (B8–B4–B3), complementada con la

capa base de Google Satellite. Se seguirán los siguientes criterios durante la digitalización:

- Cada polígono debe contener únicamente píxeles de una sola clase, evitando zonas de mezcla o bordes difusos entre categorías.
- Los polígonos de cada clase deben distribuirse en distintas zonas de la ROI para capturar la variabilidad espectral intraclase.
- El tamaño mínimo de cada polígono equivale a 3×3 píxeles (900 m^2 a resolución de 10 m) para reducir el efecto de borde del ráster.
- Se busca un mínimo de 500 píxeles por clase y una proporción máxima de 3:1 entre la clase más representada y la menos representada, para evitar sesgos en el entrenamiento.

4.3. Estructura del archivo TSV

El dataset de entrenamiento se exportará como archivo de texto separado por tabulaciones (`.tsv`). Cada fila corresponde a un píxel individual y contiene las siguientes columnas:

Cuadro 8: Estructura del archivo TSV de entrenamiento

Nº	Columna	Tipo	Descripción
1	Latitude	float64	Latitud del centroide del píxel (WGS84, grados decimales)
2	Longitude	float64	Longitud del centroide del píxel (WGS84, grados decimales)
3	B2	float32	Reflectancia de superficie — Banda Azul (490 nm)
4	B3	float32	Reflectancia de superficie — Banda Verde (560 nm)
5	B4	float32	Reflectancia de superficie — Banda Roja (665 nm)
6	B5	float32	Reflectancia de superficie — Red Edge 1 (705 nm)
7	B6	float32	Reflectancia de superficie — Red Edge 2 (740 nm)
8	B7	float32	Reflectancia de superficie — Red Edge 3 (783 nm)
9	B8	float32	Reflectancia de superficie — NIR (842 nm)
10	B8A	float32	Reflectancia de superficie — NIR estrecho (865 nm)
11	B11	float32	Reflectancia de superficie — SWIR-1 (1610 nm)
12	B12	float32	Reflectancia de superficie — SWIR-2 (2190 nm)
13	class_id	int8	Código entero de la clase (1–5, ver Tabla 5)
14	class_name	str	Etiqueta textual de la clase

4.4. Flujo de trabajo y herramientas

1. **Descarga:** Obtención del producto Sentinel-2 L2A desde Copernicus Data Space Ecosystem (<https://dataspace.copernicus.eu>), filtrando por fecha y cobertura nubosa inferior al 5 %.

2. **Preparación en QGIS:** Composición del *stack* multibanda, carga de capa base de referencia y digitalización de polígonos de entrenamiento exportados en formato GeoPackage (.gpkg).
3. **Extracción en Python:** Uso de rasterio para la lectura de las bandas ráster y de geopandas para la intersección entre los polígonos de entrenamiento y el ráster. Cada píxel contenido en un polígono se convierte en una fila del dataset.
4. **Exportación:** El dataframe resultante se exporta con pandas al formato .tsv con separador de tabulación y codificación UTF-8.
5. **Control de calidad:** Verificación del conteo de píxeles por clase, ausencia de valores nulos y rango válido de reflectancias (0.0 – 1.0 para el nivel L2A).

5. Cronograma de Actividades — Fase 1

Cuadro 9: Plan de trabajo Semana 1 — sigmasboys

Día(s)	Actividad	Responsable(s)
1 – 2	Revisión bibliográfica del Mar de Aral, selección del período de análisis y definición de clases de cobertura	Todos
2 – 3	Descarga y verificación del producto Sentinel-2 L2A desde Copernicus Data Space	Joshua / David
3 – 4	Digitalización de polígonos de entrenamiento en QGIS y validación visual de pureza espectral	Juan Diego / Joan
4 – 5	Desarrollo del script de extracción ráster–vector y generación del archivo TSV	Joshua / David
5 – 7	Control de calidad del dataset, estadísticas descriptivas por clase y redacción del informe de la Fase 1	Todos

6. Correcciones y Ajustes Realizados

Durante el desarrollo del proyecto se realizaron múltiples correcciones y ajustes metodológicos con base en las observaciones realizadas por el docente. Estas modificaciones permitieron mejorar la calidad del dataset, optimizar el proceso de entrenamiento y asegurar la coherencia metodológica del pipeline de clasificación supervisada.

6.1. Ajustes en la Construcción del Dataset

Inicialmente se habían definido regiones de entrenamiento demasiado extensas, lo que ocasionaba una cantidad excesiva de píxeles de entrenamiento y un desbalance potencial en el procesamiento de los modelos. Debido a esto, se replanteó la estrategia de selección de muestras, utilizando múltiples polígonos pequeños y homogéneos para cada clase.

Adicionalmente, se estableció como criterio mínimo contar con al menos 2000 píxeles por clase y un mínimo total de 10000 píxeles dentro del dataset final, garantizando así una representación adecuada de cada categoría utilizada en el entrenamiento.

6.2. Corrección de Atributos de Clasificación

Se modificó la estructura de la capa vectorial de entrenamiento para utilizar únicamente el atributo:

`class_name`

eliminando identificadores adicionales como campos `id`, con el fin de simplificar el procesamiento y mantener compatibilidad directa con el pipeline de Machine Learning desarrollado en Python.

6.3. Selección Temporal de Imágenes

Se decidió trabajar únicamente con una única fecha de adquisición Sentinel-2 para evitar inconsistencias espectrales asociadas a cambios temporales, iluminación, humedad o variaciones atmosféricas entre diferentes escenas satelitales.

Esto permitió mantener consistencia radiométrica durante todo el proceso de extracción de píxeles y entrenamiento supervisado.

6.4. Eliminación de Índices Espectrales

Inicialmente se contempló el uso de índices espectrales; sin embargo, siguiendo las recomendaciones del docente, se decidió trabajar exclusivamente con las bandas espectrales originales de Sentinel-2.

Por tanto, el dataset final fue construido únicamente a partir de las bandas multiespectrales disponibles en el stack generado, evitando la incorporación de índices derivados que pudieran introducir redundancia o complejidad adicional en el análisis.

6.5. Organización y Repositorio

Finalmente, todos los archivos asociados al proyecto, incluyendo scripts, datasets, resultados y documentación, fueron organizados y preparados para su integración dentro del repositorio correspondiente del proyecto.

““latex id="kzwrna"”

7. Fase 2 - Construcción del Dataset y Extracción de la Zona de Estudio

La segunda fase del proyecto estuvo enfocada en la preparación de los datos de entrada para el proceso de clasificación supervisada. Esta etapa incluyó la selección de la escena satelital Sentinel-2, la extracción de la zona de estudio, la construcción del stack multibanda y la generación de las muestras de entrenamiento utilizadas posteriormente en los modelos de Machine Learning.

Extracción y Preparación de la Zona de Estudio

7.1. Selección de la Imagen Satelital

La imagen utilizada en el proyecto fue obtenida desde la plataforma Copernicus Browser, perteneciente al programa Sentinel de la Agencia Espacial Europea (ESA). Para el desarrollo del análisis se seleccionó una escena Sentinel-2 nivel L2A, correspondiente a productos con corrección atmosférica aplicada.

La selección de una única fecha de adquisición permitió mantener consistencia espectral y radiométrica durante todo el proceso de clasificación, evitando variaciones temporales relacionadas con cambios ambientales, humedad, nubosidad o diferencias de iluminación.

La escena descargada correspondió a:

- Satélite: Sentinel-2
- Producto: Level-2A (L2A)
- Tipo de resolución utilizada: 20 metros
- Plataforma de descarga: Copernicus Browser

7.2. Definición de la Zona de Estudio

Posteriormente se realizó la delimitación de la zona de interés correspondiente al área seleccionada dentro del Mar de Aral. Esta región fue escogida debido a la presencia de diferentes

coberturas superficiales claramente diferenciables espectralmente, tales como cuerpos de agua, playas salinas y zonas arenosas.

La extracción de la zona de estudio se realizó utilizando QGIS, permitiendo trabajar únicamente sobre el área relevante del proyecto y reduciendo el volumen de procesamiento asociado al raster completo descargado desde Copernicus.




Figura 1: Zona de estudio extraída desde Copernicus Browser para el desarrollo del proyecto.

7.3. Bandas Espectrales Utilizadas

Para el proceso de clasificación supervisada se trabajó exclusivamente con las bandas espectrales originales de Sentinel-2, evitando el uso de índices espectrales derivados, siguiendo las recomendaciones metodológicas establecidas para el proyecto.

Las bandas utilizadas fueron seleccionadas debido a su relevancia en la diferenciación de coberturas terrestres y características superficiales presentes en la zona de estudio.

Las bandas utilizadas en el stack multibanda fueron:

Banda	Descripción	Resolución
B2	Azul	20 m
B3	Verde	20 m
B4	Rojo	20 m
B5	Red Edge 1	20 m
B6	Red Edge 2	20 m
B7	Red Edge 3	20 m
B8A	Infrarrojo Cercano Estrecho	20 m
B11	Infrarrojo de Onda Corta 1	20 m
B12	Infrarrojo de Onda Corta 2	20 m

Cuadro 10: Bandas espectrales Sentinel-2 utilizadas en el proyecto.

7.4. Construcción del Stack Multibanda

Una vez descargadas las bandas necesarias, se procedió a construir un raster multibanda utilizando las herramientas de procesamiento raster de QGIS. Este procedimiento permitió consolidar todas las bandas espectrales en un único archivo raster, facilitando el posterior procesamiento en Python y los algoritmos de Machine Learning.

El stack multibanda final fue exportado en formato GeoTIFF (.tif), permitiendo compatibilidad directa con librerías geoespaciales como Rasterio y GDAL.

El raster generado presentó las siguientes características generales:

- Formato: GeoTIFF
- Tipo de dato: uint16
- Número de bandas: 9
- Dimensiones aproximadas: 5490 x 5490 píxeles
- Sistema de referencia espacial consistente con Sentinel-2

7.5. Generación de Muestras de Entrenamiento

Posteriormente se realizó la construcción manual de muestras supervisadas mediante polígonos de entrenamiento creados en QGIS. Estas muestras fueron utilizadas para representar de forma homogénea las diferentes clases presentes en la zona de estudio.

Las clases seleccionadas fueron:

- Agua
- Playa_sal
- Arena

Durante esta etapa se aplicaron correcciones metodológicas para evitar polígonos excesivamente grandes o mezclas entre clases, garantizando que cada región de entrenamiento representara únicamente una cobertura homogénea.

Finalmente, las muestras fueron exportadas en formato GeoPackage (.gpkg) utilizando exclusivamente el atributo:

`class_name`

el cual fue posteriormente utilizado en el pipeline de Machine Learning para la extracción automática de píxeles de entrenamiento. ““

7.6. Selección y Preparación de Bandas Espectrales

Después de definir la zona de estudio, se realizó la selección de las bandas espectrales Sentinel-2 que serían utilizadas dentro del proceso de clasificación supervisada. La selección de bandas fue realizada considerando aquellas con mayor capacidad para diferenciar cuerpos de agua, zonas salinas y superficies arenosas presentes en el área analizada.

Inicialmente, las bandas descargadas desde Copernicus se encontraban almacenadas de forma independiente en formato JPEG2000 (.jp2), por lo que fue necesario realizar un proceso de organización y consolidación dentro de QGIS.

Debido a la necesidad de mantener consistencia espacial entre todas las capas utilizadas, únicamente se seleccionaron bandas con resolución espacial de 20 metros, evitando procesos adicionales de remuestreo que pudieran alterar los valores espectrales originales.

Las bandas finalmente seleccionadas fueron:

- B2 - Azul
- B3 - Verde
- B4 - Rojo
- B5 - Red Edge 1
- B6 - Red Edge 2
- B7 - Red Edge 3
- B8A - Infrarrojo Cercano Estrecho
- B11 - Infrarrojo de Onda Corta 1
- B12 - Infrarrojo de Onda Corta 2

Estas bandas permitieron capturar diferentes respuestas espectrales asociadas a humedad, reflectancia superficial, minerales, salinidad y características del terreno presentes dentro del Mar de Aral.

7.7. Construcción del Raster Multibanda

Una vez organizadas las bandas espectrales, se procedió a construir un raster multibanda utilizando las herramientas de procesamiento raster disponibles en QGIS.

El procedimiento consistió en combinar todas las bandas seleccionadas dentro de un único archivo raster multiespectral. Este proceso permitió consolidar toda la información espectral en una sola estructura de datos compatible con los algoritmos de Machine Learning implementados posteriormente en Python.

Para la generación del raster multibanda se utilizaron herramientas equivalentes a:

- Build Virtual Raster (VRT)
- Translate (Convert Format)

Inicialmente se construyó un raster virtual (.vrt) con el objetivo de verificar la correcta alineación espacial y espectral de las bandas. Posteriormente, el raster fue exportado a formato GeoTIFF (.tif), obteniendo el archivo final utilizado durante todo el proyecto.

El raster multibanda generado presentó las siguientes características:

- Formato final: GeoTIFF (.tif)
- Número total de bandas: 9
- Resolución espacial: 20 metros
- Tipo de dato: uint16
- Dimensiones aproximadas: 5490 x 5490 píxeles

La consolidación del stack multibanda facilitó significativamente el procesamiento automatizado mediante Rasterio y Scikit-Learn, permitiendo extraer información espectral de forma eficiente durante el entrenamiento supervisado.




Figura 2: Raster multibanda construido a partir de las bandas Sentinel-2 seleccionadas.

7.8. Preparación de Polígonos de Entrenamiento

Posteriormente se realizó la construcción manual de los polígonos de entrenamiento supervisado dentro de QGIS. Estas regiones fueron utilizadas para representar muestras homogéneas de cada clase presente en la zona de estudio.




Figura 3: Selección inicial de los polígonos sobre las áreas de estudio.




Figura 4: Campo final de todos los polígonos para el entrenamiento.

La preparación de polígonos constituyó una de las etapas más importantes del proyecto, debido a que la calidad de las muestras influye directamente en el desempeño de los modelos de Machine Learning.

Inicialmente se habían definido polígonos demasiado extensos, lo que ocasionó la extracción de una cantidad excesiva de píxeles de entrenamiento. Como consecuencia, se realizó una corrección metodológica consistente en reemplazar grandes regiones por múltiples polígonos pequeños y homogéneos distribuidos en diferentes zonas de la imagen.

Cada polígono fue construido siguiendo los siguientes criterios:

- Representar únicamente una sola clase.
- Evitar bordes o zonas de transición.
- Seleccionar regiones espectralmente homogéneas.
- Distribuir muestras en diferentes sectores de la imagen.
- Evitar mezclar agua, arena y sal dentro de un mismo polígono.

Las clases utilizadas para el entrenamiento fueron:

- Agua
- Playa_sal
- Arena

Cada polígono fue almacenado dentro de una capa vectorial GeoPackage (`training.gpkg`) utilizando el atributo:




Figura 5: Asignación de clases de estudio para la creación de polígonos de entrenamiento.

class_name

el cual permitió asociar automáticamente cada píxel extraído con su clase correspondiente durante el proceso de construcción del dataset supervisado.

Finalmente, los polígonos fueron utilizados como entrada del pipeline automatizado desarrollado en Python, permitiendo extraer millones de valores espectrales correspondientes a las bandas Sentinel-2 seleccionadas.

8. Entrenamiento y Evaluación de Modelos de Machine Learning

Fase 3 - Clasificación Supervisada y Evaluación de Modelos

La tercera fase del proyecto estuvo enfocada en la construcción del pipeline de clasificación supervisada utilizando técnicas de Machine Learning aplicadas sobre información multiespectral Sentinel-2.

Para esta etapa se desarrolló un flujo automatizado en Python orientado a la extracción de píxeles, generación del dataset supervisado, entrenamiento de múltiples clasificadores y evaluación comparativa de desempeño.

El pipeline principal fue implementado en el archivo:

```
sentinel2_supervised_pipeline.py
```

mientras que una versión optimizada para reutilizar datasets previamente exportados fue implementada en:

```
train_from_tsv.py
```

8.1. Construcción del Dataset Supervisado

El flujo de entrenamiento inició con la lectura de los polígonos de entrenamiento almacenados en formato GeoPackage (.gpkg). Durante esta etapa se verificó la existencia de la columna de clases y de las geometrías necesarias para el proceso de extracción supervisada.

Posteriormente, el pipeline realizó múltiples procesos automáticos de validación espacial y limpieza geométrica, incluyendo:

- Eliminación de geometrías vacías.
- Corrección de polígonos inválidos.
- Reproyección automática al sistema de referencia espacial del raster.
- Verificación de consistencia espacial entre raster y vector.

Una vez validados los polígonos, se procedió a extraer los píxeles correspondientes desde el

raster multibanda Sentinel-2 mediante operaciones de enmascaramiento raster-vectorial.

Cada píxel extraído fue convertido en una fila dentro del dataset final, mientras que cada banda espectral representó una característica de entrada para los modelos de Machine Learning.

El dataset generado incluyó:

- Valores espectrales de las bandas Sentinel-2.
- Etiqueta de clase correspondiente.
- Eliminación de valores nodata.
- Filtrado de datos no válidos o infinitos.

Finalmente, el dataset completo fue exportado en formato TSV (.tsv) para facilitar reproducibilidad y reutilización posterior.

8.2. División de Datos Train/Test

Después de la construcción del dataset supervisado, las clases fueron codificadas mediante el uso de:

LabelEncoder

permitiendo transformar las etiquetas categóricas en valores numéricos compatibles con Scikit-Learn.

Posteriormente, el dataset fue dividido en conjuntos de entrenamiento y prueba utilizando un *split* estratificado. Esta estrategia permitió conservar la distribución original de clases en ambos subconjuntos, evitando sesgos durante la evaluación de desempeño.

La división fue realizada utilizando:

- 70 % para entrenamiento.
- 30 % para validación y prueba.
- Semilla aleatoria fija para reproducibilidad experimental.

8.3. Modelos de Machine Learning Utilizados

El pipeline implementó múltiples algoritmos clásicos de clasificación supervisada con el objetivo de comparar desempeño y seleccionar el modelo más robusto para el problema planteado.

Los modelos entrenados fueron:

- Decision Tree
- Support Vector Machine (SVM)

- K-Nearest Neighbors (KNN)
- Gaussian Naive Bayes
- Multi-Layer Perceptron (MLP)
- Random Forest

Para los modelos sensibles a escalamiento de variables, se incorporó:

StandardScaler

dentro de un pipeline de procesamiento, permitiendo normalizar automáticamente los valores espectrales antes del entrenamiento.

Adicionalmente, el sistema incluyó soporte opcional para:

GridSearchCV

permitiendo realizar ajuste automático de hiperparámetros y optimización de desempeño mediante validación cruzada.

8.4. Métricas de Evaluación

La evaluación de desempeño fue realizada utilizando múltiples métricas estándar de clasificación multiclase, con el objetivo de analizar tanto precisión global como equilibrio entre categorías.

Las métricas calculadas fueron:

- Accuracy
- Precision Macro
- Recall Macro
- F1 Macro
- Coeficiente Kappa de Cohen

Estas métricas permitieron evaluar la capacidad de generalización de cada clasificador y analizar el comportamiento frente a posibles confusiones espectrales entre clases similares.

Además, para cada modelo entrenado se generaron:

- Matrices de confusión.
- Reportes completos de clasificación.
- Gráficas comparativas de desempeño.

8.5. Resultados Experimentales

Durante el proceso de entrenamiento se evaluaron múltiples algoritmos de clasificación supervisada con el objetivo de comparar desempeño y seleccionar el modelo más adecuado para la clasificación multiespectral Sentinel-2.

Cada modelo fue entrenado utilizando el dataset supervisado construido a partir de los píxeles extraídos desde los polígonos de entrenamiento. Posteriormente, los modelos fueron evaluados utilizando el conjunto de prueba generado mediante división estratificada.

El proceso completo generó múltiples salidas experimentales, incluyendo métricas de desempeño, matrices de confusión, rankings comparativos y modelos serializados.

8.6. Resumen del Dataset Utilizado

El pipeline reportó la siguiente configuración experimental:

- Número total de características espectrales: 9 bandas Sentinel-2.
- Clases detectadas: Arena, Agua y Playa_sal.
- Tamaño máximo utilizado por clase: 100000 píxeles.
- Total de muestras utilizadas: 200000 píxeles.
- Conjunto de entrenamiento: 150000 muestras.
- Conjunto de prueba: 50000 muestras.

8.7. Métricas Comparativas de los Modelos

Los modelos entrenados fueron evaluados utilizando Accuracy, Precision Macro, Recall Macro, F1 Macro y coeficiente Kappa de Cohen.

Los resultados obtenidos fueron los siguientes:

Modelo	Accuracy	Precision	Recall	F1 Macro	Kappa
MLPClassifier	0.8422	0.8425	0.8422	0.8421	0.6844
RandomForest	0.8376	0.8385	0.8376	0.8374	0.6752
KNN	0.8285	0.8295	0.8285	0.8284	0.6571
SVM	0.8097	0.8207	0.8097	0.8081	0.6195
DecisionTree	0.7845	0.7845	0.7845	0.7845	0.5690
GaussianNB	0.7225	0.7655	0.7225	0.7108	0.4450

Cuadro 11: Comparación de desempeño entre los modelos de clasificación supervisada.

8.8. Selección del Mejor Modelo

A partir de las métricas obtenidas, el modelo con mejor desempeño general fue:

MLPClassifier

Este modelo obtuvo los valores más altos tanto en F1 Macro como en coeficiente Kappa, indicando un mejor equilibrio entre precisión y capacidad de generalización.

El uso de una arquitectura Multi-Layer Perceptron permitió capturar relaciones no lineales complejas entre las bandas espectrales Sentinel-2, mejorando la separación entre clases espectralmente similares.

8.9. Matrices de Confusión

Para cada uno de los modelos entrenados se generó una matriz de confusión con el objetivo de analizar detalladamente los errores de clasificación entre clases.

Estas matrices permitieron identificar:

- Clases con mayor tasa de confusión.
- Errores sistemáticos de clasificación.
- Capacidad discriminativa de cada modelo.
- Balance entre falsos positivos y falsos negativos.

A continuación se presentan los espacios reservados para las matrices de confusión generadas durante el entrenamiento experimental.

8.9.1. Matriz de Confusión - Decision Tree




Figura 6: Matriz de confusión obtenida para el modelo Decision Tree.

8.9.2. Matriz de Confusión - SVM




Figura 7: Matriz de confusión obtenida para el modelo SVM.

8.9.3. Matriz de Confusión - KNN




Figura 8: Matriz de confusión obtenida para el modelo KNN.

8.9.4. Matriz de Confusión - GaussianNB




Figura 9: Matriz de confusión obtenida para el modelo GaussianNB.

8.9.5. Matriz de Confusión - MLPClassifier




Figura 10: Matriz de confusión obtenida para el modelo MLPClassifier.

8.9.6. Matriz de Confusión - Random Forest




Figura 11: Matriz de confusión obtenida para el modelo Random Forest.

8.10. Archivos y Resultados Generados

El pipeline generó automáticamente múltiples artefactos de salida asociados al proceso experimental.

Entre los principales archivos obtenidos se encuentran:

- Dataset supervisado en formato TSV.
- Ranking comparativo de modelos.
- Métricas exportadas en CSV.
- Matrices de confusión en PNG.
- Modelo final serializado en formato joblib.
- Reportes automáticos de clasificación.
- Gráficas comparativas de desempeño.

Estos resultados permitieron garantizar trazabilidad experimental, reproducibilidad y documentación completa del proceso de clasificación supervisada.

9. Conclusiones de la Fase de Entrenamiento y Clasificación Supervisada

La fase de entrenamiento y evaluación de modelos permitió validar la viabilidad del uso de técnicas de Machine Learning aplicadas sobre imágenes multiespectrales Sentinel-2 para tareas de clasificación supervisada en entornos de percepción remota.

Uno de los principales resultados obtenidos fue la construcción exitosa de un pipeline automatizado capaz de integrar procesamiento geoespacial, extracción de píxeles, generación de datasets supervisados, entrenamiento de modelos y evaluación comparativa dentro de un único flujo reproducible.

Durante el proceso experimental se evidenció la importancia de la calidad de las muestras de entrenamiento. La corrección de polígonos excesivamente grandes y la utilización de regiones homogéneas permitió reducir ruido espectral y mejorar significativamente el comportamiento de los clasificadores.

Asimismo, se comprobó que el uso exclusivo de bandas espectrales originales de Sentinel-2 fue suficiente para obtener resultados competitivos, evitando la necesidad de incorporar índices espectrales adicionales.

En términos de desempeño, los modelos basados en aprendizaje no lineal obtuvieron mejores resultados frente a clasificadores más simples. Particularmente, el modelo `MLPClassifier` presentó el mejor equilibrio entre precisión, capacidad de generalización y estabilidad, alcanzando los mayores valores de F1 Macro y coeficiente Kappa dentro del conjunto experimental.

Los resultados también demostraron que algoritmos como Random Forest y KNN poseen un desempeño robusto para problemas de clasificación multiespectral, mientras que modelos probabilísticos más simples, como Gaussian Naive Bayes, presentaron mayores limitaciones frente a clases con respuestas espectrales similares.

Otro aspecto relevante fue la capacidad del pipeline para producir automáticamente múltiples artefactos de validación y documentación, incluyendo métricas, rankings, modelos serializados y reportes exportables, fortaleciendo la reproducibilidad experimental y la trazabilidad metodológica del proyecto.

En términos generales, esta etapa permitió consolidar una metodología robusta para clasificación supervisada en GeoAI, integrando herramientas de percepción remota, análisis geoespacial y aprendizaje automático dentro de un flujo moderno y escalable para análisis de imágenes satelitales Sentinel-2.

10. Fase 3 - Cambios Implementados para la Tercera Entrega (Retroalimentación Fase 2 y Resultados Fase 3)

A partir de la retroalimentación obtenida durante la segunda fase del proyecto, se realizaron diversos ajustes sobre la construcción del dataset de entrenamiento y la definición de las clases de cobertura utilizadas en el proceso de clasificación supervisada. Estos cambios fueron determinantes para alcanzar los resultados que se presentan en esta sección.

10.1. Redefinición de las Clases de Estudio

Inicialmente se contemplaba trabajar con un mayor número de clases de cobertura superficial. En la segunda fase se habían trabajado 3 clases por simplicidad, pero la idea original era llegar hasta 5 clases para tener un análisis más detallado. Sin embargo, tras analizar cuidadosamente la calidad espectral de la imagen y la separabilidad visual observada en la zona de estudio, y siguiendo las recomendaciones del docente, se decidió concentrar el análisis en tres categorías claramente diferenciables:

- **Agua:** remanentes del Small Aral y cuerpos de agua dispersos en el antiguo lecho.
- **Arena:** dunas y superficies arenosas del desierto de Aralkum.
- **Playa_sal:** costras salinas expuestas tras el retroceso del agua.

Esta decisión permitió reducir drásticamente la ambigüedad espectral entre categorías y mejorar significativamente la calidad de las muestras utilizadas para el entrenamiento. El docente sugirió que, para efectos de este proyecto, era mejor priorizar la pureza espectral de las muestras sobre la cantidad de clases, ya que un modelo bien entrenado con pocas clases pero bien definidas es más útil que un modelo confuso con muchas clases.

10.2. Actualización de los Polígonos de Entrenamiento

Se realizó una nueva fase de digitalización manual dentro de QGIS con el objetivo de construir polígonos más representativos y distribuidos espacialmente sobre toda la región de estudio. Esta fue una de las correcciones más importantes solicitadas por el docente.

A diferencia de la primera versión del dataset, donde se usaban polígonos muy extensos que abarcaban cientos de píxeles de una sola vez, en esta etapa se seleccionaron múltiples polígonos pequeños y homogéneos para cada clase. Se incluyeron también pequeñas zonas de transición entre coberturas para que el modelo aprenda a manejar los bordes de manera adecuada, pero siempre asegurando que la mayoría de los polígonos representaran zonas puras.

Debido a que las tres clases seleccionadas presentan diferencias visuales y espectrales muy marcadas dentro de la imagen Sentinel-2 (el agua aparece oscura, la arena clara y las playas de sal casi blancas con textura rugosa), fue posible aumentar la cantidad de muestras sin introducir ruido significativo en el conjunto de entrenamiento. El contraste extremo entre estas coberturas es una característica particular del Mar de Aral en la temporada de verano,

con cielo despejado y alta radiación solar.




Figura 12: Polígonos de entrenamiento utilizados para la construcción del dataset supervisado. Se muestran las tres clases distribuidas en múltiples zonas de la imagen.

10.3. Distribución Final de Muestras

La extracción automática de píxeles realizada mediante el pipeline desarrollado en Python produjo un conjunto de entrenamiento balanceado entre las tres clases seleccionadas. Se estableció un mínimo de 2000 píxeles por clase como criterio de calidad, y se logró superar ampliamente este umbral.

La distribución obtenida fue la siguiente:

Clase	Píxeles	Porcentaje
Playa_sal	27 941	34.52 %
Agua	27 112	33.50 %
Arena	25 889	31.98 %

Cuadro 12: Distribución final de píxeles extraídos para entrenamiento.

Los resultados muestran una distribución casi perfectamente balanceada entre las tres clases, con diferencias de menos de 3 puntos porcentuales entre la clase más representada y la menos representada. Esto reduce drásticamente la posibilidad de sesgos durante el entrenamiento de los modelos de clasificación, ya que ninguno de los clasificadores tenderá a favorecer una clase sobre otra por simple mayoría de muestras.

10.4. Entrenamiento y Evaluación de Modelos

Con el dataset corregido y balanceado, se procedió a entrenar seis modelos de clasificación supervisada: Decision Tree, SVM, KNN, Gaussian Naive Bayes, MLPClassifier y Random Forest. Se aplicó una optimización exhaustiva de hiperparámetros mediante GridSearchCV con validación cruzada 5-fold, lo que significa que cada combinación de hiperparámetros se probó 5 veces con diferentes particiones de los datos de entrenamiento. Para los modelos sensibles a la escala de las variables (especialmente SVM, KNN y MLP), se aplicó escalamiento de características con StandardScaler, que transforma los valores espectrales para que tengan media cero y desviación estándar uno.

Las métricas de evaluación utilizadas fueron Accuracy (precisión global), Precision Macro (promedio de la precisión por clase), Recall Macro (promedio de la exhaustividad por clase), F1 Macro (media armónica entre precisión y recall) y el coeficiente Kappa de Cohen (que mide la concordancia más allá del azar).

Los resultados obtenidos fueron los siguientes:

Modelo	Accuracy	Precision	Recall	F1 Macro	Kappa
SVM	1.0000	1.0000	1.0000	1.0000	1.0000
KNN	1.0000	1.0000	1.0000	1.0000	1.0000
MLPClassifier	1.0000	1.0000	1.0000	1.0000	1.0000
RandomForest	1.0000	1.0000	1.0000	1.0000	1.0000
DecisionTree	0.9999	0.9999	0.9999	0.9999	0.9999
GaussianNB	0.9863	0.9867	0.9861	0.9863	0.9795

Cuadro 13: Resultados de clasificación de los seis modelos evaluados.

La razón de estos resultados tan excepcionales radica en las características particulares de

la zona de estudio elegida. El Mar de Aral, durante el verano, presenta tres condiciones que favorecen enormemente la clasificación espectral:

1. **Baja nubosidad:** la región de Asia Central tiene una de las tasas más bajas de nubosidad en verano, lo que garantiza imágenes limpias sin sombras ni interferencias atmosféricas.
2. **Alto contraste espectral:** el agua residual tiene una firma espectral completamente diferente a la arena y a las costras salinas. La arena refleja fuertemente en el infrarrojo, mientras que el agua lo absorbe casi por completo. Las costras salinas tienen un comportamiento intermedio pero con picos característicos en bandas específicas.
3. **Uniformidad intra-clase:** dentro de cada clase, las variaciones espectrales son mínimas. Por ejemplo, toda el agua del Small Aral tiene composición química homogénea, y las arenas del desierto de Aralkum son muy uniformes en composición mineralógica.

Por estas razones, los modelos de clasificación pueden aprender los patrones espectrales de cada clase con muy pocos ejemplos y generalizar perfectamente al resto de la escena.

10.5. Selección del Mejor Modelo

Cinco modelos alcanzaron métricas perfectas ($F1 = 1.0$, $Kappa = 1.0$). Para la selección final se aplicaron criterios de desempate cuidadosamente considerados:

- **Tiempo de entrenamiento:** se midió el tiempo que cada modelo tardó en entrenarse con el dataset de 80.942 muestras.
- **Simplicidad del modelo:** se prefirieron modelos con menos hiperparámetros y menor complejidad matemática.
- **Eficiencia computacional para inferencia:** se evaluó la velocidad de clasificación sobre la escena completa de 30 millones de píxeles.
- **Interpretabilidad:** se consideró la facilidad para explicar por qué el modelo toma ciertas decisiones.

El modelo seleccionado como mejor fue:

Support Vector Machine (SVM)

La elección de SVM responde a múltiples razones. En primer lugar, su robustez teórica para clasificación en espacios de alta dimensionalidad (como los 9 bandas espectrales que usamos) está ampliamente documentada en la literatura de percepción remota. En segundo lugar, su capacidad para encontrar hiperplanos óptimos de separación mediante la función kernel (en nuestro caso usamos kernel lineal por la separabilidad perfecta de las clases) garantiza que la solución encontrada sea la mejor posible desde el punto de vista matemático. En tercer lugar, SVM demostró ser computacionalmente eficiente durante la inferencia sobre la escena completa de 30 millones de píxeles, clasificando la imagen completa en menos tiempo que

MLPClassifier o Random Forest. Finalmente, SVM es más interpretable que una red neuronal, ya que los vectores de soporte pueden visualizarse y analizarse directamente.

10.6. Matrices de Confusión

Las matrices de confusión confirmaron la ausencia total de errores de clasificación entre las tres coberturas. Esto significa que ninguno de los píxeles de agua fue clasificado como arena o sal, y viceversa. Es importante notar que este nivel de precisión perfecta en validación cruzada es inusual en problemas de clasificación de imágenes satelitales, y refleja la alta calidad tanto del dataset como de las características espectrales seleccionadas.




Figura 13: Matriz de confusión del modelo SVM. Las diagonales muestran 100 % de aciertos para las tres clases.




Figura 14: Matriz de confusión del modelo Random Forest, mostrando también un desempeño perfecto.

10.7. Visualización del Raster de Entrada

Una vez construido el stack multibanda, se realizó una inspección visual para verificar la correcta alineación espacial de las bandas y la calidad general de la escena utilizada. El raster resultante tiene dimensiones de 5490×5490 píxeles, lo que equivale a una extensión aproximada de 110 km × 110 km (considerando la resolución de 20 metros por píxel).




Figura 15: Raster multibanda utilizado como entrada para el proceso de clasificación supervisada. La composición en falso color resalta las diferencias entre agua, arena y sal.

10.8. Superposición entre Raster y Polígonos

Con el fin de validar visualmente las muestras de entrenamiento, se verificó la ubicación de todos los polígonos sobre la imagen satelital utilizada. Esta verificación permitió confirmar que los polígonos no cruzaban bordes entre clases y que efectivamente representaban zonas puras o con transiciones controladas.




Figura 16: Superposición de los polígonos de entrenamiento sobre el raster Sentinel-2. Cada color representa una clase diferente.

La distribución espacial de las muestras permitió capturar diferentes condiciones presentes dentro de cada categoría (por ejemplo, agua profunda vs. agua somera, arena gruesa vs. arena fina, sal cristalizada vs. sal pulverulenta), mejorando significativamente la representatividad del conjunto de entrenamiento.

10.9. Organización de Capas en QGIS

Durante el proceso de construcción del dataset se trabajó con múltiples capas raster y vectoriales dentro de QGIS. La organización adecuada de estas capas permitió facilitar la validación visual y el control de calidad de las muestras utilizadas. Se crearon grupos de capas para separar los datos brutos (bandas Sentinel-2), los datos procesados (stack multibanda) y las muestras de entrenamiento (polígonos).




Figura 17: Capas utilizadas durante la construcción del dataset de entrenamiento en QGIS.

11. Generación del Mapa Clasificado con SVM

Una vez seleccionado el modelo SVM como mejor clasificador, se procedió a clasificar la totalidad del raster multibanda utilizando el archivo:

`predict_raster.py`

Este script carga el modelo SVM entrenado, lo aplica píxel a píxel sobre las 9 bandas del raster de entrada, y genera un nuevo raster de salida donde cada valor entero representa una clase (0 para Agua, 1 para Arena, 2 para Playa_sal). El proceso de inferencia sobre 30 millones de píxeles tomó aproximadamente 2 minutos en un equipo estándar, lo que confirma la eficiencia computacional del SVM.

Las clases y colores utilizados para la visualización final fueron seleccionados para asemejarse lo más posible a la apariencia real de las coberturas observada en Google Maps:

Clase	Color	Código HEX
Agua	Verde azulado oscuro	#034142
Arena	Marrón grisáceo	#8B806E
Playa_sal	Beige claro	#E0D6CC

Cuadro 14: Simbología utilizada para la visualización del mapa clasificado.




Figura 18: Mapa clasificado generado mediante el modelo SVM. Se aprecian claramente las tres coberturas: agua (azul verdoso), arena (marrón) y playa de sal (beige).

11.1. Capas Finales del Proyecto

La integración de las capas finales permitió verificar simultáneamente el raster original, las muestras de entrenamiento y el resultado de clasificación generado por el modelo. Esta visualización múltiple es útil para identificar posibles errores sistemáticos, como zonas donde el modelo clasificó incorrectamente áreas que visualmente parecen pertenecer a otra clase.




Figura 19: Visualización de las capas finales utilizadas en el proyecto dentro de QGIS.

12. Cálculo de Áreas por Clase

Con el objetivo de cuantificar la extensión ocupada por cada cobertura identificada, se desarrolló el script:

`calculate_areas.py`

El procedimiento contabilizó el número total de píxeles clasificados en cada categoría y posteriormente convirtió dichos valores a unidades de superficie utilizando la resolución espacial de 20 metros por píxel. La fórmula de conversión es:

$$\text{Área (ha)} = \frac{\text{Número de píxeles} \times (20\text{ m})^2}{10,000\text{ m}^2/\text{ha}}$$

Los resultados obtenidos fueron los siguientes:

Clase	Área (ha)	Área (km ²)	Píxeles
Agua	88 083.32	880.83	2 202 083
Arena	763 158.84	7 631.59	19 078 971
Playa_sal	354 361.84	3 543.62	8 859 046

Cuadro 15: Área estimada por clase obtenida a partir del mapa clasificado.

Los resultados evidencian el predominio de superficies arenosas dentro de la zona estudiada, con 763.158 hectáreas que representan casi el 60 % del área total de estudio (1.205.604 hectáreas). Le siguen las extensas áreas de costras salinas con 354.362 hectáreas (aproximadamente el 29 %), y finalmente los cuerpos de agua remanentes con 88.083 hectáreas (apenas el 7 % restante). Es importante destacar que estos valores son consistentes con los reportados por la literatura científica sobre la desecación del Mar de Aral, que indica que el lago original de 68.000 km² se ha reducido a menos del 10 % de su extensión histórica.

13. Comparación Visual con Google Maps

Como mecanismo de validación visual cualitativa, se comparó el resultado obtenido mediante clasificación supervisada con imágenes recientes disponibles en Google Maps. Esta comparación es útil porque Google Maps utiliza imágenes satelitales de alta resolución de múltiples fuentes, lo que proporciona una referencia independiente para evaluar la calidad de nuestra clasificación.



Figura 20: Referencia visual de la zona de estudio observada desde Google Maps. Se aprecian las mismas tres coberturas identificadas por nuestro modelo.

La comparación visual muestra una correspondencia consistente entre las coberturas identificadas por el modelo y las características observables en la imagen de referencia, especialmente en:

- La delimitación de cuerpos de agua: el modelo identificó correctamente los límites del Small Aral y los canales remanentes.
- Las playas salinas: las áreas blancas brillantes en Google Maps coinciden exactamente con las zonas clasificadas como Playa_sal.
- Las extensiones arenosas: las áreas de color marrón claro en Google Maps corresponden a las zonas de Arena.

Esta validación cualitativa refuerza la confianza en los resultados cuantitativos presentados en la sección anterior.

14. Conclusión

El presente proyecto desarrolló un flujo completo de clasificación supervisada de imágenes satelitales Sentinel-2 aplicado al análisis de la degradación ambiental del Mar de Aral. A lo largo de las tres fases del proyecto, se logró integrar herramientas de percepción remota, sistemas de información geográfica y aprendizaje automático para cuantificar y visualizar la transformación de las coberturas del suelo en una de las zonas con mayor impacto ambiental antropogénico del mundo.

14.1. Logros Alcanzados

En la primera fase se definió el problema, seleccionando la cuenca del Mar de Aral como región de interés y estableciendo las bases metodológicas del proyecto. Se identificaron las coberturas espectralmente relevantes y se definieron los criterios para la construcción del dataset de entrenamiento.

En la segunda fase, tras recibir retroalimentación del docente, se implementaron correcciones fundamentales: se redujeron los polígonos de entrenamiento de grandes extensiones a múltiples regiones pequeñas y homogéneas, se limitó el análisis a tres clases espectralmente puras (Agua, Arena, Playa_sal), y se aseguró una distribución balanceada con aproximadamente 27 000 píxeles por clase. Estas correcciones resultaron determinantes para la calidad del dataset.

En la tercera fase se entrenaron seis modelos de clasificación supervisada (SVM, KNN, MLP, Random Forest, Decision Tree y Gaussian Naive Bayes) utilizando optimización de hiperparámetros con GridSearchCV y validación cruzada 5-fold. Los resultados mostraron que SVM, KNN, MLP y Random Forest alcanzaron métricas perfectas (Accuracy = 1.0, F1 = 1.0, Kappa = 1.0), evidenciando que las tres coberturas seleccionadas presentan firmas espectrales claramente diferenciables en las bandas Sentinel-2.

14.2. Selección del Modelo y Generación del Mapa

El modelo SVM fue seleccionado como mejor clasificador debido a su robustez teórica, eficiencia computacional y menor dependencia de ajustes complejos en comparación con redes neuronales. Posteriormente, el modelo fue desplegado sobre la escena completa de 5490×5490 píxeles (aproximadamente 12.056 km²), generando un mapa temático de coberturas con simbología personalizada (Agua: #034142, Arena: #8B806E, Playa_sal: #E0D6CC).

14.3. Cuantificación de Áreas

El análisis cuantitativo reveló que la cobertura dominante en la zona de estudio es la arena, con 763.158,84 hectáreas (7.631,59 km²), lo que representa aproximadamente el 63 % del área total clasificada. Le sigue la playa de sal con 354.361,84 hectáreas (3.543,62 km²), correspondiente al 29 %, y finalmente el agua con 88.083,32 hectáreas (880,83 km²), equivalente al 8 % restante. Estos valores reflejan la magnitud de la desecación del antiguo lecho del Mar de Aral, donde los cuerpos de agua remanentes ocupan menos de una décima parte del área que alguna vez cubrieron.

14.4. Validación y Significancia

La validación visual mediante comparación con imágenes de Google Maps confirmó la consistencia de los resultados: las áreas clasificadas como agua coinciden con los remanentes del Small Aral, las zonas de playa de sal se corresponden con las costras blancas observables en el antiguo lecho, y las extensiones de arena coinciden con el desierto de Aralkum.

El proyecto demuestra que es posible realizar monitoreo ambiental de alta precisión utilizando únicamente bandas espectrales originales de Sentinel-2, sin necesidad de índices derivados, siempre que se cuente con un conjunto de entrenamiento bien construido. La metodología desarrollada es reproducible y escalable, pudiendo aplicarse a otras regiones de interés para el estudio de fenómenos de cambio global como la desertificación, la salinización o la pérdida de cuerpos de agua.

14.5. Trabajo Futuro

Como líneas de trabajo futuro, queremos sugerir algo como estudiantes: sería muy decente extender el análisis a múltiples fechas para evaluar la tasa de cambio de las coberturas a lo largo del tiempo, lo que permitiría cuantificar la velocidad de avance del desierto de Aralkum.

En síntesis, creemos que el proyecto cumplió con todos los objetivos planteados: se implementó un pipeline completo de clasificación supervisada, se compararon seis arquitecturas de aprendizaje automático, se generó un mapa temático de coberturas y se cuantificaron las áreas afectadas por la desecación del Mar de Aral. Los resultados obtenidos constituyen una herramienta útil para la comprensión y monitoreo de este desastre ambiental, demostrando el potencial para el análisis de fenómenos de cambio global.

Referencias

- [1] Micklin, P. (2016). The future of the Aral Sea: hope and despair. *The Geographical Journal*, 182(2), 116–127. <https://doi.org/10.1111/geoj.12174>
- [2] ESA. (2025). *Earth from Space: The shrinking Aral Sea*. European Space Agency. Copernicus Sentinel data (2025), procesado por ESA. https://www.esa.int/ESA_Multimedia/Images/2025/04/Earth_from_Space_The_shrinking_Aral_Sea
- [3] ESA. (2024). *Sentinel-2 MSI — User Guides: Spatial Resolutions*. Sentinel Online. <https://sentinel.esa.int/web/sentinel/user-guides/sentinel-2-msi/resolutions/spatial>
- [4] ESA. (2024). *Sentinel-2 Auxiliary and Data Product Specification — MSI*. Copernicus EOPF. <https://s2.pages.eopf.copernicus.eu/pdfs-adfs/MSI/index.html>
- [5] NASA Earthdata. (2025). *Sentinel-2 Multispectral Imager (MSI)*. NASA EOSDIS. <https://www.earthdata.nasa.gov/data/instruments/sentinel-2-msi>
- [6] USGS EROS. (2024). *Aral Sea, Kazakhstan and Uzbekistan — EarthShots*. U.S. Geological Survey. <https://eros.usgs.gov/earthshots/aral-sea-kazakhstan-and-uzbekistan>
- [7] UNCCD. (2025). *Witnessing an environmental catastrophe: Reflections from the dried-up Aral Sea*. United Nations Convention to Combat Desertification. <https://www.unccd.int/news-stories/special-feature/witnessing-environmental-catastrophe-reflection>
- [8] Britannica. (2026). *Aral Sea*. Encyclopædia Britannica. Última actualización: 28 de marzo de 2026. <https://www.britannica.com/place/Aral-Sea>
- [9] Gillies, S., et al. (2019). *Rasterio: Geospatial Raster I/O for Python Programmers*. Mapbox. <https://github.com/rasterio/rasterio>
- [10] Jordahl, K., et al. (2021). *GeoPandas v0.9.0*. Zenodo. <https://doi.org/10.5281/zenodo.5573592>
- [11] Main-Knorn, M., et al. (2017). Sen2Cor for Sentinel-2. *Proceedings SPIE 10427, Image and Signal Processing for Remote Sensing XXIII*. <https://doi.org/10.1117/12.2278218>